

1 引言

面向智能交通、移动机器人和现场视觉分析等应用，DNN 推理结果只有在规定时间内返回才具有服务价值。将推理服务部署在靠近数据源的网络边缘，能够减少对远程云中心的依赖，并为实时感知与决策提供邻近算力。然而，边缘设备的资源规模有限，请求又会持续到达，因此系统不仅要完成推理，还需要在长期运行中控制请求级时效风险 [1]–[4]。

实际边缘推理平台通常同时承载多种 DNN 服务。不同模型具有不同的计算开销、到达过程和服务级目标（Service-Level Objective, SLO）；本文用模型级请求 deadline 表示该目标，并将超时完成记为一次服务级协议（Service-Level Agreement, SLA）违约。与此同时，高吞吐 GPU 与低功耗片上系统等执行设备在服务能力、能耗和 batch 扩展效率上存在差异，单一设备难以在所有模型和 batch size 下始终占优。因此，多 DNN 队列、异构执行设备与模型级 deadline 需要被统一考虑 [4]–[7]。

动态组批使上述问题进一步转化为紧密耦合的在线联合决策。等待更多同类请求可以形成较大 batch，提升硬件并行度并分摊执行开销，但等待本身会消耗 deadline 裕量；立即派发小 batch 可缩短排队时间，却可能降低吞吐并增加并发竞争。调度器还需决定服务哪个 DNN 队列、将 batch 派发到哪台设备，以及当前是否执行 WAIT。一次动作不仅影响当前请求，还会改变后续队列积压、设备槽位和其他模型的可服务机会 [5], [8], [9]。

这一联合决策必须在持续变化的运行条件下在线完成。短时间内的请求到达强度和模型组成可能发生波动，共置 batch 之间的资源竞争也会使实际执行时间偏离孤立运行时的基准水平 [2], [3], [10], [11]。调度器无法预先获知未来请求，也不能读取真实负载系数、场景标签或隐藏干扰变量，只能依据当前队列与设备状态、已经揭示的到达事件以及已完成 batch 的执行反馈不断更新决策。

本文聚焦请求到达边缘入口后的在线服务调度。每个请求的 DNN 类型和模型级 deadline 由应用预先给定，调度器不改变模型、不执行网络切分、输入压缩或精度调整，也不分配无线资源。系统按照 DNN 类型维护 FIFO 队列，并由一个集中式调度器管理多个异构执行设备。默认 deployment-aware 实验会为所有方法叠加同分布、动作无关的客户端上行时延，以评估其对 SLA slack 的消耗；该上行不进入策略状态、动作或训练目标。

现有工作已经从动态 batching、并发控制、异构执行、deadline-aware queue ordering 和学习式调度等角度改善边缘 DNN serving，因此本文不把采用 DRL 或 batching 本身视为创新。仍待解决的是三个彼此耦合的问题：第一，单个事件需要在 DNN 队列、执行设备、batch size 与 WAIT 之间作出结构化联合选择，而扁平动作编号难以表达候选动作之间共享的模型、设备与服务属性；第二，到达强度、模型 mix 和共运行性能可能随时间变化，调度器却不能读取未来请求、真实负载系数或隐藏干扰，只能依赖已揭示到达和完成反馈；第三，模型级 deadline 违约、连续尾部风险和单位请求能耗预算具有不同语义，固定标量奖励难以同时刻画。本文据此建立统一系统模型，并设计 RiskBudget-SAC。

为解决上述问题，本文提出 **RiskBudget-SAC**，一种面向异构多 DNN 边缘推理服务的事件驱动在线调度框架。其一，调度器不把离散动作仅视为互不相关的编号，而是显式编码候选动作对应的 DNN 队列、执行设备、batch size、WAIT 标识及基准服务属性，并结合动作局部状态进行候选评分。其二，调度器仅利用已揭示的到达事件和已完成 batch 反馈估计当前负载与执行偏移，在压力或 deadline 紧迫时选择性收缩可选动作集合；训练阶段再通过模型级 SLA 对偶、物理时间尾风险代理和 profile-estimated 能耗预算共同塑造策略。该设计不读取未来请求、真实负载系数、场景标签或隐藏干扰变量。

总体而言，本文研究 edge-ingress 多 DNN 服务中的队列选择、设备路由、动态组批与等待控制，目标是在预定义的 profile-estimated 单位请求能耗预算内降低请求级 SLA 违约率和 p99 时延。本文不将经验 p99 直接作为可微训练目标，而是利用连续尾部风险代理改善其在线表现。主要贡献如下：

- **问题与系统建模。** 本文构建一个面向 edge-ingress 多 DNN 服务的事件驱动联合调度模型，在每个事件上统一选择 DNN 队列、异构执行设备、batch size 或 WAIT，并显式描述模型级 deadline、设备并发槽位、时变到达、隐藏运行时减速和 profile-estimated 单位请求能耗预算。
- **动作语义对齐的 SAC 调度器。** 本文设计 action-semantic Actor 与 action-aligned twin Critics，将候选动作的模型、设备、batch 和基准服务属性与其局部队列、设备状态对齐后逐动作评分，以利用联合动作之间可共享的结构，而不是仅学习扁平动作编号。
- **基于已揭示反馈的风险控制。** 本文利用在线到达估计和已完成 batch 反馈构造选择性 Risk Gate，并通过模型级 SLA 对偶、尾风险代理和估计能耗预算协同训练策略。历史反馈编码、tail-focused replay 与物理时间 n-step 作为该机制的状态和训练实现，不被单独视为核心创新。
- **严格边界下的实验验证。** 在一个冻结的 400-episode 训练检查点上，本文使用每条件 5 个 paired evaluation seeds，并在默认动作无关上行配置下对测试条件等权宏平均。相对各指标对应的最强 baseline，RiskBudget-SAC 在静态和动态场景中的 SLA 违约率分别平均降低约 18.3% 和 9.35%，deployment-aware p99 分别平均降低约 32.2% 和 34.6%，同时将 profile-estimated 单位请求能耗保持在约 0.109587 J/request 的预设预算内。该结果不表示所有负载或所有指标均占优，也不代表多训练种子稳定性。

参考文献

- [1] D. Spatharakis, C. Pelekis, D. Dechouniotis, and S. Papavasileiou, “A task offloading and batch scheduling framework for edge-assisted inference,” *Future Gener. Comput. Syst.*, vol. 175, Art. no. 108030, 2026, doi: 10.1016/j.future.2025.108030.
- [2] Z. Zhao, N. Ling, N. Guan, and G. Xing, “Miriam: Exploiting elastic kernels for real-time multi-DNN inference on edge GPU,” in *Proc. 21st ACM Conf. Embedded Networked Sensor Syst. (SenSys)*, 2023, pp. 97–110, doi: 10.1145/3625687.3625789.
- [3] T.-T. Nguyen, L. Liebe, N.-Q. Tau, Y. Wu, J. Cheng, and D. Lee, “OctopInf: Workload-aware inference serving for edge video analytics,” in *Proc. IEEE Int. Conf. Pervasive Comput. Commun. (PerCom)*, 2025, pp. 128–137, doi: 10.1109/PerCom64205.2025.00032.

- [4] N. Ling, W. Lu, X. Huang, Z. Zhao, N. Guan, Z. Yan, and G. Xing, “Time-sensitive multi-DNN inference on CPU-GPU edge platforms,” *IEEE Trans. Mobile Comput.*, vol. 25, no. 5, pp. 6168–6184, May 2026, doi: 10.1109/TMC.2025.3636950.
- [5] Z. Zhang, Y. Zhao, H. Li, and J. Liu, “BCEdge: SLO-aware DNN inference services with adaptive batch-concurrent scheduling on edge devices,” *IEEE Trans. Netw. Service Manag.*, vol. 21, no. 4, pp. 4131–4145, 2024, doi: 10.1109/TNSM.2024.3409701.
- [6] S. Heidari, M. Ghasemi, Y. G. Kim, C.-J. Wu, and S. B. K. Vrudhula, “Elastic execution of multi-tenant DNNs on heterogeneous edge MPSoCs,” in *Proc. IEEE/ACM Symp. Edge Comput. (SEC)*, 2024, pp. 279–291, doi: 10.1109/SEC62691.2024.00029.
- [7] Q. Liang, W. A. Hanafy, N. Bashir, A. Ali-Eldin, D. Irwin, and P. Shenoy, “Dēlen: Enabling flexible and adaptive model-serving for multi-tenant edge AI,” in *Proc. ACM/IEEE Conf. Internet Things Design Implementation (IoTDI)*, 2023, pp. 209–221, doi: 10.1145/3576842.3582375.
- [8] G. Zhang, Y. Zhang, X. Huang, and W. Zhang, “Coinf: QoS-aware DRL-based inference task scheduling framework with batching processing,” *ACM Trans. Embedded Comput. Syst.*, vol. 25, no. 1, Art. no. 3, 20 pp., Jan. 2026, doi: 10.1145/3777373.
- [9] J. Cao, X. Li, Q. Liu, T. Han, N. Zhang, and W. Shi, “EdgeServing: Deadline-aware multi-DNN serving at the edge,” *arXiv:2605.05527*, 2026.
- [10] H. Zhang, Y. Tang, A. Khandelwal, and I. Stoica, “SHEPHERD: Serving DNNs in the wild,” in *Proc. 20th USENIX Symp. Networked Syst. Design Implementation (NSDI)*, 2023, pp. 787–808.
- [11] Y. Kim, I. Kim, K. Choi, J. Ahn, J. Park, and J. Huh, “Interference-aware DNN serving on heterogeneous processors in edge systems,” in *Proc. IEEE 42nd Int. Conf. Comput. Design (ICCD)*, 2024, pp. 199–206, doi: 10.1109/ICCD63220.2024.00038.