

4 RiskBudget-SAC 方法

RiskBudget-SAC 按“已揭示信息建模、选择性风险筛选、动作语义评分和尾部风险预算训练”四个环节运行。在线阶段，调度器只使用当前队列与设备状态、已经发生的到达和已完成 batch 反馈；Risk Gate 先从第三章定义的物理动作中构造非空可选集合，Actor 再完成最终动作选择。训练阶段，Twin Critics 利用模型级 SLA 偏差、连续尾部风险代理和 profile-estimated 能耗预算学习长期价值。GRU、EWMA、平衡回放、物理时间 n-step、目标网络与熵调节均作为该流程的配套实现，而非彼此独立的贡献。

4.1 方法总览与信息边界

在事件时刻 t_k ，策略可观察各 DNN 队列长度和 slack 分布、设备占用与并发组成、近期已揭示到达统计，以及最近完成 batch 的执行反馈。策略不读取环境设置中的真实到达率、未来请求、场景名称、运行时减速因子或隐藏干扰强度。由第三章式 (5) 得到的物理动作集合首先保证队列、batch 与设备容量约束；Risk Gate 只在此基础上选择性收缩动作集合，不生成新动作，也不替代 Actor 排序。

方法的两个核心设计分别对应第三章的两类困难：动作语义评分利用 DNN、设备、batch 和基准服务属性之间的共享结构，避免把有限动作库仅视为互不相关的编号；基于已揭示反馈的风险控制则利用在线到达估计和完成反馈，在负载压力或 deadline 紧迫时限制明显不利的探索，并通过软约束训练塑造长期策略。

4.2 已揭示到达与完成反馈表征

调度器在每个事件上刷新即时状态 s_k ，其中包含各 DNN 的队列与 deadline 裕量、设备占用和并发执行组成。为反映短时到达变化，对最近长度为 Δ 的观测窗口计数，并按模型使用 EWMA 更新在线到达率：

$$\begin{aligned} \hat{\lambda}_{m,k} &= (1 - \alpha_\lambda) \hat{\lambda}_{m,k-1} \\ &\quad + \alpha_\lambda \frac{A_m(t_k - \Delta, t_k)}{\Delta}. \end{aligned} \quad (18)$$

式 (18) 中， $\hat{\lambda}_{m,k}$ 仅由截至 t_k 已到达的请求更新， $\alpha_\lambda \in (0, 1]$ 为平滑系数。所有 episode 采用统一冷启动，不从环境读取真实 $\lambda_m(t)$ 、模型 mix 或未来计数。

执行时间估计以第三章的基准 profile 为起点，并由相同 DNN-设备组合的已完成 batch 反馈进行保守校正。设 $\mu^p_{m,d,k}$ 和 $\sigma^p_{m,d,k}$ 分别为截至 t_k 观测到的执行时延比值的 EWMA 均值和标准差，则

$$\begin{aligned}
u_{m,d,k}^\rho &= \mu_{m,d,k}^\rho + \chi \sigma_{m,d,k}^\rho, \\
\hat{\rho}_{m,d,k} &= \text{clip}(u_{m,d,k}^\rho, \rho_{\min}, \rho_{\max}), \\
\hat{T}_k(m, d, b) &= \bar{T}_{m,d,b} \hat{\rho}_{m,d,k}.
\end{aligned} \tag{19}$$

式 (19) 中, $u_{m,d,k}^\rho$ 为加入不确定性裕量后的时延比值, 观测比值由已完成 batch 的实际执行时延除以相应基准执行时延得到; χ 控制裕量大小, $\text{clip}(\cdot)$ 将修正限制在预设区间。该预测器不读取正在运行 batch 的真实减速因子, 只利用完成后已经揭示的反馈。

令 $\mathcal{H}_k$ 表示 t_k 前最近 H 条已完成 batch 的反馈窗口。每条记录包含完成时间的新近程度、DNN 类型、执行设备、batch size, 以及相对于基准 profile 的执行时延和能耗比值。GRU 按完成顺序编码该窗口, 并与即时状态组成 Actor 和 Critic 的上下文:

$$h_k = \text{GRU}_\omega(\mathcal{H}_k), c_k = [s_k, h_k]. \tag{20}$$

式 (20) 中, h_k 是固定维度的历史表示, ω 为 GRU 参数, c_k 为后续策略和值函数使用的完整上下文。 $\hat{\lambda}_k$ 与动作完成时间估计主要供 Risk Gate 判断压力和紧迫度; 它们不被作为额外 oracle 变量直接拼入 Actor。

4.3 反馈校准的选择性 Risk Gate

Risk Gate 的输入始终受第三章式 (5) 限定。它读取物理动作集合、当前可观测状态、在线到达率估计和以完成反馈校正的动作时延估计, 并返回非空风险动作集合:

$$\begin{aligned}
\mathcal{A}_k^{\text{risk}} &= G\left(\mathcal{A}_k^{\text{phy}}, s_k, \hat{\lambda}_k, \hat{T}_k\right), \\
\mathcal{A}_k^{\text{risk}} &\neq \emptyset.
\end{aligned} \tag{21}$$

式 (21) 中, $G(\cdot)$ 表示选择性 Risk Gate, $\hat{T}_k$ 以物理派发动作为索引。Gate 先根据 $P_{m,k} = \frac{q_m(t_k)}{\max(\lambda_{m,k} \delta_m, I)}$ 估计各模型队列压力, 并计算队首请求的归一化 slack。低压力且无紧迫请求时, Gate 保留全部物理可行动作; 压力升高时, 它聚焦压力最大的 DNN 队列, 并保留预测服务率接近该队列当前最佳值的派发动作; 存在紧迫请求时, 则优先筛选预测完成时刻仍留有安全裕量的动作。

若紧迫队列不存在预测可及时完成的动作, Gate 不返回空集合, 而是保留预计按时吞吐率较高的动作; 若所有候选均预计超时, 则退回到服务率较高的动作以继续排空积压。Gate 只构造允许集合, 最终的 DNN、设备和 batch 决策仍由 Actor 作出。该筛选降低明显高风险探索的机会, 但不构成确定性安全或 SLA 保证。

Algorithm 1: 反馈校准的选择性 Risk Gate

Input: 当前可观测状态 s_k 、物理动作集合 $\mathcal{A}_k^{\text{phy}}$ 、已揭示到达、已完成 batch 反馈、基准服务特性

Output: 非空动作集合 $\mathcal{A}_k^{\text{risk}}$

- 1 用截至 t_k 的到达事件按式 (18) 更新各 DNN 的在线到达率估计。
- 2 同步新完成 batch 的执行时延比值，并按式 (19) 更新对应 DNN-设备组合的保守完成时间修正。
- 3 由当前队列、模型级 deadline 和 $\hat{\lambda}_k$ 计算模型级压力，并读取各队首请求的归一化 slack。
- 4 若不存在紧迫请求且最大压力低于阈值，则返回原物理动作集合 A_k^{phy} 。
- 5 若不存在紧迫请求但压力较高，则选取压力最大的 DNN，并保留预测服务率达到该 DNN 最佳值给定比例的派发动作。
- 6 若存在紧迫请求，则只考察最紧迫 DNN 的物理派发动作，并根据 $\hat{T}_k$ 与请求 deadline 筛选具有完成裕量的动作。
- 7 若没有预计可及时完成的动作，则保留预计按时吞吐率最高的一组动作；若其均为零，则退回到服务率最高的一组动作。
- 8 若任一分支产生空集合，则返回原物理动作集合中的可行动作，确保系统能够继续推进。

4.4 动作语义对齐的 SAC 调度器

对每个候选动作，RiskBudget-SAC 不仅保留动作编号，还编码其可共享语义。动作特征由 WAIT 标识、DNN one-hot、执行设备 one-hot、batch size 的双尺度表示和第三章式 (7) 的基准服务属性组成：

$$\begin{aligned}
 \phi(\text{WAIT}) &= [1 \cdot \mathbf{0}]^T, \\
 \phi(m, d, b) &= [0, \mathbf{e}_m^T, \mathbf{e}_d^T, \psi(b)^T, \mathcal{P}_{m,d,b}^T]^T, \\
 \psi(b) &= [\log_2 b \cdot b]^T.
 \end{aligned} \tag{22}$$

式 (22) 中， $\mathbf{e}_m$ 和 $\mathbf{e}_d$ 分别为 DNN 与设备的 one-hot 向量。 $\psi(b)$ 同时保留 batch size 的对数尺度和线性尺度，以区分倍增关系与绝对大小。连续特征在送入网络前按照固定参考尺度归一化；WAIT 的非适用字段置零。

Actor 分别编码上下文与动作语义。基础评分头根据当前上下文为有限动作库给出初始分数，动作条件残差头再利用共享动作表示进行校正：

$$\begin{aligned}
 z_k &= f_{\theta}^{\text{ctx}}(c_k), \\
 u_a &= f_{\theta}^{\text{act}}(\phi(a)), \\
 \ell_k(a) &= g_{\theta}^{\text{base}}(z_k)_a + g_{\theta}^{\text{res}}(z_k, u_a).
 \end{aligned} \tag{23}$$

式 (23) 中， f_{ctx} 和 f_{act} 是上下文与动作 MLP 编码器， z_k 和 u_a 为相应隐表示。基础头保留对每个有限动作的直接评分能力，残差头则利用状态-动作交互对其修正，使具有相同 DNN、设备或相近 batch 属性的动作能够共享统计信息。该式省略了实现中的逐元素交互特征，但不改变“基础评分加动作语义残差”的结构。

策略只在 Risk Gate 保留的动作集合内归一化：

$$\begin{aligned}
 \pi_{\theta}(a|c_k) &= \frac{\mathbb{I}[a \in \mathcal{A}_k^{\text{risk}}] \exp(\ell_k(a))}{\sum_{\tilde{a} \in \mathcal{A}_k^{\text{risk}}} \exp(\ell_k(\tilde{a}))}.
 \end{aligned} \tag{24}$$

式 (24) 的 **masked softmax** 保证被物理约束或 **Gate** 排除的动作概率为零。训练时从该分布随机采样以维持探索；评估和部署时直接选择概率最大的单个动作，不执行候选搜索或多次试选。

两个独立 **Critic** 在全局上下文与静态动作语义之外，还读取与候选动作对应的局部状态。对派发动作，该局部状态包含目标 **DNN** 的队列、队首 **slack** 与分布特征，以及目标设备的占用、并发组成和可观测干扰水平；**WAIT** 则使用相应全局聚合表示。**Twin Critics** 定义为

$$\begin{aligned} Q_{\psi_j}(c_k, a) \\ = F_{\psi_j}(c_k, \phi(a), s_{k,a}^{\text{loc}}), j \in \{1, 2\}. \end{aligned} \quad (25)$$

式 (25) 中， F_{ψ_j} 是第 j 个动作对齐价值网络， $s_{k,a}^{\text{loc}}$ 是从当前可观测状态中提取的动作相关局部信息。两个 **Critic** 结构相同但参数独立，并在 **Bellman target** 和 **Actor** 更新中采用较小预测值，以抑制价值高估。

4.5 尾部风险预算训练

经验 **p99** 只有在收集完整请求 **cohort** 后才能计算，难以为每个事件提供及时训练信号。为此，本文根据当前队列积压与队首 **slack** 构造连续尾部风险水平，并对一个动作持续期间的风险进行梯形积分近似：

$$\begin{aligned} \xi_{m,k} &= \frac{q_m(t_k)}{\max(\lambda_{m,k} \delta_{\text{ref}}, l)} [\eta_s - \tilde{s}_{m,k}]_+^p, \\ R_k &= \text{clip}(\sum_{m \in \mathcal{M}} \xi_{m,k} \theta C_{\max}), \\ c_k^{\text{tail}} &= \frac{R_k + R_{k+1}}{2} \frac{\Delta t_k}{\delta_{\text{ref}}}. \end{aligned} \quad (26)$$

式 (26) 中， $\xi_{m,k}$ 表示模型 m 在事件 k 的尾部风险贡献， $\tilde{s}_{m,k}$ 为其队首请求的归一化 **slack**， η_s 为风险触发阈值， p 控制对紧迫程度的非线性放大， δ_{ref} 是时间归一化常数， Δt_k 为动作持续时间。 R_k 为事件时刻的总体风险水平， $C_{\max}$ 为其数值截断上限。只有 **slack** 低于阈值的积压进入风险项，长时间占用设备的动作会按持续时间承担更高代价。 $\text{clip}(\cdot)$ 用于限制极端积压对数值稳定性的影响。该代理用于训练，不与式 (15) 的经验 **p99** 混同。

每个物理时间 **n-step** 转移同时保存模型级违约计数、纳入 **SLA** 统计的请求数和 **profile-estimated** 能耗。**Critic** 更新时使用当前模型级对偶变量重构即时奖励：

$$\begin{aligned}
r_k &= -\kappa c_k^{\text{tail}} \\
&- \kappa \sum_{m \in \mathcal{M}} \lambda_{m,k}^{\text{SLA}} (v_{m,k} - \varepsilon_m n_{m,k}) \\
&- \kappa [\hat{e}_k - E_{\max} n_k]_+, \\
n_k &= \sum_{m \in \mathcal{M}} n_{m,k}.
\end{aligned} \tag{27}$$

式 (27) 中, $v_{m,k}$ 和 $n_{m,k}$ 分别为聚合转移内模型 m 的违约请求数与 SLA 统计请求数, $\lambda_{m,k}^{\text{SLA}}$ 为模型级对偶权重; $v_{m,k} - \varepsilon_m n_{m,k}$ 为相对允许违约比例的偏差。 $\hat{e}_k$ 为转移累计的 profile-estimated 能耗, 只有超过 $E_{\max} n_k$ 的部分受到惩罚。 $[x]_+ = \max(x, 0)$, $\kappa > 0$ 为统一奖励尺度。回放缓冲区保存这些组成分量, 训练时按当前对偶权重重构 r_k , 从而使历史转移与更新后的约束压力一致。

每个 episode 结束后, 模型级 SLA 对偶变量按照观测违约率更新:

$$\begin{aligned}
u_{m,k} &= \lambda_{m,k}^{\text{SLA}} + \eta_\lambda (\hat{v}_{m,k} - \varepsilon_m), \\
\lambda_{m,k+l}^{\text{SLA}} &= \Pi_{[\lambda_{\min}, \lambda_{\max}]}(u_{m,k}).
\end{aligned} \tag{28}$$

式 (28) 中, $u_{m,k}$ 为投影前的对偶更新值, $\hat{v}_{m,k}$ 为本 episode 的模型级违约率, η_λ 为对偶学习率, Π 为区间投影。违约率高于目标时, 对应模型的后续惩罚增强; 低于目标时则减弱。独立对偶变量避免宽松模型的结果掩盖紧 deadline 模型。

事件动作具有不同持续时间。令 N_k 为从事件 k 开始, 最先达到预设物理时间窗、最大决策数或 episode 边界的聚合步数, 并令 $\Delta_{k,\ell} = \sum_{u=0}^{\ell-1} \Delta t_{k+u}$ 。物理时间 n-step soft target 为

$$\begin{aligned}
R_k^{(N)} &= \sum_{\ell=0}^{N_k-1} e^{-\beta \Delta_{k,\ell}} r_{k+\ell}, \\
\bar{Q}_{k+N_k}(a') &= \min_{j \in \{1,2\}} Q_{\bar{\psi}_j}(c_{k+N_k}, a') \\
&- \alpha \log \pi_\theta(a' | c_{k+N_k}), \\
\bar{V}_{k+N_k} &= \sum_{a' \in \mathcal{A}_{k+N_k}^{\text{risk}}} \pi_\theta(a' | c_{k+N_k}) \bar{Q}_{k+N_k}(a') \\
y_k^{(N)} &= R_k^{(N)} \\
&+ e^{-\beta \Delta_{k,N_k}} (1 - d_{k+N_k-1}) \bar{V}_{k+N_k}.
\end{aligned} \tag{29}$$

式 (29) 中, $R_k^{(N)}$ 为按物理时间折扣的 N-step 累计奖励, $\bar{Q}_{k+N_k}(a')$ 为包含策略熵项的保守目标动作价值, $\bar{V}_{k+N_k}$ 为门控动作集合上的期望后续价值。 β 为物理时间折扣率, d 为 episode 终止标记, $Q_{\bar{\psi}_j}$ 为目标 Critic, α 为熵温度。回报按真实经过时间折扣, 而不是假设 WAIT 与不同 batch 动作具有相同持续步长; episode 终止时后续价值被置零。

Twin Critics 通过同一 target 进行均方误差回归:

$$\mathcal{L}_{Q,j} = \mathbb{E}_{\mathcal{D}} \left[\left(Q_{\psi_j}(c_k, a_k) - y_k^{(N)} \right)^2 \right], j \in \{1, 2\}, \quad (30)$$

$$\min_{\psi_1, \psi_2} \mathcal{L}_Q = \frac{1}{2} (\mathcal{L}_{Q,1} + \mathcal{L}_{Q,2}).$$

式 (30) 中, $\mathcal{L}_{Q,j}$ 为第 j 个在线 Critic 的 Bellman 均方误差, $\mathcal{D}$ 为经验回放分布。回放先按训练场景平衡, 再提高高压力和高尾部风险转移的采样比例, 同时保留均匀样本以维持整体价值估计。训练还将部分当前尾部代价归因给仍在阻塞相关请求的先前 batch 派发, 使早期占用决策获得风险信号。目标 Critic 不参与反向传播, 并通过 Polyak 更新缓慢跟随在线 Critic。

Actor 在门控动作集合上采用离散 SAC 的最大熵目标:

$$\begin{aligned} Q_k^{\min}(a) &= \min_{j \in \{1, 2\}} Q_{\psi_j}(c_k, a), \\ g_{\pi,k}(a) &= \alpha \log \pi_{\theta}(a|c_k) - Q_k^{\min}(a), \\ J_{\pi,k} &= \sum_{a \in \mathcal{A}_k^{\text{risk}}} \pi_{\theta}(a|c_k) g_{\pi,k}(a), \\ \min_{\theta} \mathcal{L}_{\pi} &= \mathbb{E}_{c_k \sim \mathcal{D}} [J_{\pi,k}]. \end{aligned} \quad (31)$$

式 (31) 中, $Q_k^{\min}(a)$ 为两个在线 Critic 对动作 a 的较小价值预测, $g_{\pi,k}(a)$ 为相应的最大熵策略代价, $J_{\pi,k}$ 为当前上下文下的期望策略代价。该目标在训练期兼顾价值改进与策略熵。熵温度依据门控后有效动作数调节, 避免因不同状态下可行动作数量变化而产生不一致探索压力。Critic、Actor、熵温度和目标网络的更新共同构成 Algorithm 2。

Algorithm 2: 尾部风险预算 SAC 训练

Input: 训练场景分布、基准服务特性、物理动作库、SLA 阈值 ϵ_m 与能耗预算 $E_{\max}$

Output: 训练后的确定性 Actor、GRU 编码器、到达率估计器与完成时间校正器

- 1 初始化 Actor、两个在线 Critic 及目标 Critic、经验回放、模型级 SLA 对偶变量和反馈估计器。
- 2 在每个 episode 重置环境、EWMA 到达率估计和完成反馈游标; 不注入真实负载率、未来请求或隐藏干扰。
- 3 在事件 t_k 根据当前可观测状态和历史反馈按式 (18)–(20) 构造上下文。
- 4 由第三章式 (5) 构造物理动作集合, 并调用 Algorithm 1 得到非空 Risk Gate 动作集合。
- 5 训练期从式 (24) 的门控策略采样动作, 执行环境并记录持续时间、下一状态、违约计数、请求计数、估计能耗和式 (26) 的尾部风险。
- 6 将转移写入物理时间 n -step 累加器; 达到时间窗、最大决策数或 episode 边界时, 把聚合转移写入按场景、压力和尾部风险组织的 replay buffer。
- 7 达到更新条件后采样 replay, 按当前 SLA 对偶变量用式 (27) 重构奖励, 并用式 (29) 计算 soft target。
- 8 按式 (30) 更新两个在线 Critic, 按式 (31) 更新 Actor 与熵温度, 再对目标 Critic 执行 Polyak 软更新。
- 9 episode 结束并排空到达 cohort 后, 计算各 DNN 的违约率并按式 (28) 更新模型级对偶变量。

10 重复上述过程直至训练结束，保存一个冻结策略检查点用于所有后续评估。

4.6 部署路径与计算复杂度

部署时移除 Twin Critics、经验回放、梯度更新和 SLA 对偶更新。系统仅保留已揭示到达率 EWMA、完成时间校正器、GRU 历史编码器、Risk Gate 和一次确定性 Actor 前向计算。每个事件先构造物理与风险动作集合，再对所有保留动作进行一次向量化评分并选择概率最大的动作；不执行环境内候选搜索，不读取未来请求、真实负载率、场景标签或隐藏干扰变量。

设当前物理动作数为 $|\mathcal{A}_k^{\text{phy}}|$ ，历史窗口长度为 H ，且隐层宽度固定。到达统计和历史编码的开销分别随 DNN 数量与 H 线性增长；完成时间估计、Risk Gate 和动作评分均至多对有限动作库扫描一次，因此单事件决策复杂度关于 $|\mathcal{A}_k^{\text{phy}}|$ 为线性量级。动作语义编码和局部状态提取可预计算或向量化，不引入多候选 rollout 或在线组合搜索。