

2 相关工作

本节围绕异构多 DNN 服务与动态组批、学习式联合调度与风险控制，以及相邻的 MEC 卸载与协同推理研究展开，并从决策范围、可观测反馈和风险目标三个方面说明本文的研究边界。

2.1 异构多 DNN 服务与动态组批

多 DNN 在线服务需要同时处理模型间执行差异、batch 扩展特性和设备并发能力。增大 batch 通常能够提高吞吐并分摊执行开销，但也会增加组批等待；异构设备在不同模型和 batch size 下的优势并不一致，共置执行还可能引入资源竞争。因此，batch size、并发度和执行设备需要结合队列状态与 deadline 共同配置。

HarmonyBatch 面向具有不同 SLO 的 DNN 请求，在异构 CPU/GPU serverless functions 上联合完成请求分组与资源配置 [19]。ELTO 使用实测性能数据和回归预测在线调整动态组批参数，以权衡推理时延与能耗 [20]。BCEdge 则联合调节 batch size 和并发实例数，以改善边缘设备上的多 DNN 服务效率并满足 SLO [5]。这些方法表明，动态 batching 和并发控制本身已是边缘推理服务中的成熟研究方向。

在执行机制方面，Miriam 通过弹性 GPU kernel 协调实时多 DNN 推理 [2]。OctopInf 面向动态边缘视频分析，将工作负载感知的跨设备分配、动态 batching 和共置调度结合起来 [3]。Ling 等研究 CPU-GPU 边缘平台上的时敏多 DNN 推理 [4]，Heidari 等关注异构边缘 MPSoC 上多租户 DNN 的弹性执行 [6]，Delen 则提供面向多租户边缘 AI 的自适应模型服务机制 [7]。此外，Kim 等直接分析异构处理器上的 DNN 共置干扰，并据此改进 serving 决策 [11]。

上述研究已经覆盖动态 batching、异构执行和共置干扰中的多个关键环节，但这些能力并不自动等价于本文关注的事件级结构化联合动作。本文要求调度器在同一决策中选择 DNN 队列、执行设备、batch size 或 WAIT，并在缺少未来负载和隐藏运行时变量的条件下控制风险。

2.2 学习式联合调度、SLA 与尾部风险

强化学习可通过环境交互学习当前调度动作对后续队列、吞吐和截止期限风险的长期影响。BCEdge 采用最大熵深度强化学习联合控制 batch size 与并发实例数 [5]。Coinf 结合性能预测识别紧急任务，并利用深度强化学习选择 QoS 感知的 batching 动作 [8]。Sun 等进一步采用离散 Soft Actor-Critic 联合学习任务卸载与 SLA 感知组批策略 [21]。因此，使用 DRL、SAC、性能预测或 urgency-aware batching 本身并不是本文的新意。

面向 deadline 和尾部性能，EdgeServing 协调多个 DNN 队列的服务顺序，以降低 deadline 违约风险 [9]。TailGuard 针对用户服务的尾部时延 SLO 设计任务级调度机制

[22]。SHEPHERD 对生产 DNN 服务负载的研究还表明，在线工作负载在短时间尺度上具有明显变化，仅依赖长期均值难以完整刻画服务压力 [10]。这些工作说明 deadline awareness、尾部目标和动态状态适应均已具有充分研究基础。

本文关注的是上述能力尚未完全覆盖的组合边界：在单个事件上联合选择 queue、device、batch 与 WAIT；显式表示候选动作语义，并使价值网络读取与该动作对应的局部状态；仅依据已揭示到达和完成反馈适应隐藏运行变化；同时区分模型级 SLA 阈值、连续 tail-risk surrogate 与 profile-estimated 能耗预算。RiskBudget-SAC 据此将结构化动作评分与选择性风险控制组织在同一在线策略中。

2.3 相邻的 MEC 卸载与协同推理

传统 MEC 研究主要决定任务在终端、边缘节点和云端之间的执行位置，并常与无线资源、计算资源或能耗控制联合优化 [12]。强化学习进一步被用于适应动态信道、任务依赖和多工作负载变化 [13]。例如，Sharma 等将具有依赖关系的任务表示为有向无环图并采用元强化学习进行边云卸载 [14]；Ke 等利用模块化 SAC 处理多工作负载和多 MEC 服务器的卸载决策 [15]；TF-DDRL 通过 Transformer 增强的分布式强化学习学习边云 IoT 调度 [16]。这些方法的主要动作通常是执行位置、资源份额或 DAG 调度，与持续服务队列中的 route-batch-WAIT 决策不同。

协同推理研究则进一步考虑 DNN 模型结构与硬件特性。DVFO 联合选择 DNN 切分位置及 CPU、GPU 和内存的动态电压频率，以降低边云协同推理的时延与能耗 [17]。Qian 等采用循环深度强化学习联合配置无线资源、卸载比例与边缘侧多 DNN 推理 [18]。Spatharakis 等还联合决定本地或远程模型、输入压缩和任务卸载，以权衡推理精度与端到端时延 [1]。这些工作同时控制通信、切分、压缩或精度变量，而本文从请求到达 edge ingress 后开始，不优化无线资源、模型切分、输入压缩或精度选择。因此，FGCS 2026 的问题与本文相邻，但并非完全同问题的直接 baseline。

2.4 研究空缺总结

综上，现有研究已分别验证动态 batching、并发控制、deadline-aware queue ordering、性能预测和学习式调度的有效性，因而本文不把使用 SAC、GRU 或 batching 本身视为创新。本文关注的尚未充分解决的组合是：调度器在 edge ingress 处面对多个 DNN FIFO 队列和异构执行设备，需要在单个事件上联合选择队列、设备、batch size 或 WAIT；同时，策略不能读取未来到达、真实负载系数和隐藏运行时干扰，只能利用已揭示到达与完成反馈；控制目标还需区分模型级 SLA 阈值、尾部风险和 profile-estimated 能耗预算。第三章据此定义联合动作、信息边界与软约束控制目标，第四章再给出 RiskBudget-SAC 的对应实现。

参考文献

- [1] D. Spatharakis, C. Pelekis, D. Dechouniotis, and S. Papavasileiou, “A task offloading and batch scheduling framework for edge-assisted inference,” *Future Gener. Comput. Syst.*, vol. 175, Art. no. 108030, 2026, doi: 10.1016/j.future.2025.108030.
- [2] Z. Zhao, N. Ling, N. Guan, and G. Xing, “Miriam: Exploiting elastic kernels for real-time multi-DNN inference on edge GPU,” in *Proc. 21st ACM Conf. Embedded Networked Sensor Syst. (SenSys)*, 2023, pp. 97–110, doi: 10.1145/3625687.3625789.
- [3] T.-T. Nguyen, L. Liebe, N.-Q. Tau, Y. Wu, J. Cheng, and D. Lee, “OctopInf: Workload-aware inference serving for edge video analytics,” in *Proc. IEEE Int. Conf. Pervasive Comput. Commun. (PerCom)*, 2025, pp. 128–137, doi: 10.1109/PerCom64205.2025.00032.
- [4] N. Ling, W. Lu, X. Huang, Z. Zhao, N. Guan, Z. Yan, and G. Xing, “Time-sensitive multi-DNN inference on CPU-GPU edge platforms,” *IEEE Trans. Mobile Comput.*, vol. 25, no. 5, pp. 6168–6184, May 2026, doi: 10.1109/TMC.2025.3636950.
- [5] Z. Zhang, Y. Zhao, H. Li, and J. Liu, “BCEdge: SLO-aware DNN inference services with adaptive batch-concurrent scheduling on edge devices,” *IEEE Trans. Netw. Service Manag.*, vol. 21, no. 4, pp. 4131–4145, 2024, doi: 10.1109/TNSM.2024.3409701.
- [6] S. Heidari, M. Ghasemi, Y. G. Kim, C.-J. Wu, and S. B. K. Vrudhula, “Elastic execution of multi-tenant DNNs on heterogeneous edge MPSoCs,” in *Proc. IEEE/ACM Symp. Edge Comput. (SEC)*, 2024, pp. 279–291, doi: 10.1109/SEC62691.2024.00029.
- [7] Q. Liang, W. A. Hanafy, N. Bashir, A. Ali-Eldin, D. Irwin, and P. Shenoy, “Dēlen: Enabling flexible and adaptive model-serving for multi-tenant edge AI,” in *Proc. ACM/IEEE Conf. Internet Things Design Implementation (IoTDI)*, 2023, pp. 209–221, doi: 10.1145/3576842.3582375.
- [8] G. Zhang, Y. Zhang, X. Huang, and W. Zhang, “Coinf: QoS-aware DRL-based inference task scheduling framework with batching processing,” *ACM Trans. Embedded Comput. Syst.*, vol. 25, no. 1, Art. no. 3, 20 pp., Jan. 2026, doi: 10.1145/3777373.
- [9] J. Cao, X. Li, Q. Liu, T. Han, N. Zhang, and W. Shi, “EdgeServing: Deadline-aware multi-DNN serving at the edge,” *arXiv:2605.05527*, 2026.
- [10] H. Zhang, Y. Tang, A. Khandelwal, and I. Stoica, “SHEPHERD: Serving DNNs in the wild,” in *Proc. 20th USENIX Symp. Networked Syst. Design Implementation (NSDI)*, 2023, pp. 787–808.
- [11] Y. Kim, I. Kim, K. Choi, J. Ahn, J. Park, and J. Huh, “Interference-aware DNN serving on heterogeneous processors in edge systems,” in *Proc. IEEE 42nd Int. Conf. Comput. Design (ICCD)*, 2024, pp. 199–206, doi: 10.1109/ICCD63220.2024.00038.
- [12] Y. Mao, C. You, J. Zhang, K. Huang, and K. B. Letaief, “A survey on mobile edge computing: The communication perspective,” *IEEE Commun. Surveys Tuts.*, vol. 19, no. 4, pp. 2322–2358, 4th Quart., 2017, doi: 10.1109/COMST.2017.2745201.
- [13] N. Yang, S. Chen, H. Zhang, and R. Berry, “Beyond the edge: An advanced exploration of reinforcement learning for mobile edge computing, its applications, and future research trajectories,” *IEEE Commun. Surveys Tuts.*, vol. 27, no. 1, pp. 546–594, Feb. 2025, doi: 10.1109/COMST.2024.3405075.
- [14] N. Sharma, A. Ghosh, R. Misra, and S. K. Das, “Deep meta Q-learning based multi-task offloading in edge-cloud systems,” *IEEE Trans. Mobile Comput.*, vol. 23, no. 4, pp. 2583–2598, Apr. 2024, doi: 10.1109/TMC.2023.3264901.
- [15] H. Ke, Y. Ding, L. Pan, Y. Chen, and J. Zhao, “Modular deep reinforcement learning for multi-workload offloading in edge networks,” in *Proc. 34th Int. Joint Conf. Artif. Intell. (IJCAI)*, 2025, pp. 5527–5535, doi: 10.24963/ijcai.2025/615.
- [16] Z. Wang, M. Goudarzi, and R. Buyya, “TF-DDRL: A Transformer-enhanced distributed DRL technique for scheduling IoT applications in edge and cloud computing environments,” *IEEE Trans. Services Comput.*, vol. 18, no. 2, pp. 1039–1053, Mar./Apr. 2025, doi: 10.1109/TSC.2025.3528346.
- [17] Z. Zhang, Y. Zhao, H. Li, C. Lin, and J. Liu, “DVFO: Learning-based DVFS for energy-efficient edge-cloud collaborative inference,” *IEEE Trans. Mobile Comput.*, vol. 23, no. 10, pp. 9042–9059, Oct. 2024, doi: 10.1109/TMC.2024.3357218.
- [18] W. Qian, R. W. L. Coutinho, and A. Boukerche, “Communication resource allocation and multi-DNN inference optimization in edge computing-aided video analytics,” *Comput. Commun.*, vol. 257, Art. no. 108607, 2026, doi: 10.1016/j.comcom.2026.108607.
- [19] J. Chen, F. Xu, Y. Gu, L. Chen, F. Liu, and Z. Zhou, “HarmonyBatch: Batching multi-SLO DNN inference with heterogeneous serverless functions,” in *Proc. IEEE/ACM 32nd Int. Symp. Quality Service (IWQoS)*, 2024, pp. 1–10, doi: 10.1109/IWQoS61813.2024.10682915.
- [20] I. Dokuchaev, A. K. Idrees, and R. Schuster, “ELTO: Energy-latency trade-off optimization for machine learning inference with dynamic batching,” in *Proc. 23rd Int. Symp. Netw. Comput. Appl. (NCA)*, 2025, pp. 157–164, doi: 10.1109/NCA67271.2025.00035.
- [21] J. Sun, H. Hao, H. Shi, Z. Su, H. Li, and W. Zhang, “A dynamic co-inference framework for edge-end using discrete Soft Actor-Critic and SLA-aware task batching,” in *Proc. Int. Joint Conf. Neural Netw. (IJCNN)*, 2025, pp. 1–9, doi: 10.1109/IJCNN64981.2025.11229166.
- [22] Z. Wang, H. Li, L. Sun, S. Rosenkrantz, H. Che, and H. Jiang, “A tail latency SLO guaranteed task scheduling scheme for user-facing services,” *IEEE Trans. Parallel Distrib. Syst.*, vol. 36, no. 4, pp. 759–774, Apr. 2025, doi: 10.1109/TPDS.2025.3542638.