

3 系统模型与问题表述

本文研究请求到达边缘入口后的集中式在线多 DNN 推理服务。请求按 DNN 类型进入独立 FIFO 队列，调度器在请求到达、batch 完成或等待边界等事件上作出决策，并统一管理多个执行设备。本章依次定义服务架构与请求、已揭示到达和事件级动作、基于 profile 的执行过程及隐藏运行变化，最后给出 edge-side 与 deployment-aware 两套评价口径和软约束控制目标。

3.1 边缘入口服务架构与请求模型

设 $\mathcal{M}$ 为系统承载的 DNN 服务集合， $\mathcal{D}$ 为边缘入口统一管理的执行设备集合。系统为每个 DNN 维护一条 FIFO 队列。设备 $d \in \mathcal{D}$ 可并发运行至多 C_d 个 batch，DNN $m \in \mathcal{M}$ 在设备 d 上允许采用的 batch size 集合记为 $\mathcal{B}_{m,d}$ 。每个请求只对应一种 DNN 服务，请求不可拆分；一个 batch 仅包含同一 DNN 的请求，派发后不迁移且不抢占。

第 i 个到达边缘入口的推理请求定义为

$$r_i = (t_i^{\text{arr}}, m_i, \delta_{m_i}). \quad (1)$$

式 (1) 中， t_i^{arr} 为请求 i 到达边缘入口的时刻， m_i 为其 DNN 类型， δ_{m_i} 为该模型对应的请求级相对 deadline。请求的绝对截止时刻与时刻 t 的剩余裕量分别为

$$\tau_i = t_i^{\text{arr}} + \delta_{m_i}, s_i(t) = \tau_i - t. \quad (2)$$

式 (2) 中， τ_i 表示请求 i 的绝对截止时刻， $s_i(t)$ 表示其当前 deadline 裕量； $s_i(t)$ 越小，请求越紧迫，取负值表示该请求已经超过 deadline。

表 3.1 系统对象、状态变量与性能参数

符号	定义
$\mathcal{M}$	系统提供的 DNN 服务类型集合
$\mathcal{D}$	边缘入口统一管理的执行设备集合
m	DNN 服务类型索引
d	执行设备索引
C_d	设备 d 可同时运行的 batch 数量上限
$\mathcal{B}_{m,d}$	DNN m 在设备 d 上允许采用的 batch size 集合
r_i	第 i 个到达边缘入口的推理请求
t_i^{arr}	请求 i 到达边缘入口的时刻
m_i	请求 i 对应的 DNN 类型

δ_m	DNN m 的请求级相对 deadline
τ_i	请求 i 的绝对截止时刻
$s_i(t)$	时刻 t 请求 i 的剩余 deadline 裕量
$\lambda_m(t)$	时刻 t DNN m 的环境到达强度；不作为策略直接输入
$Q_m(t)$	时刻 t DNN m 的 FIFO 等待队列
$q_m(t)$	时刻 t DNN m 的队列请求数量
t_k	第 k 个事件驱动调度时刻
a_k	调度器在 t_k 执行的联合动作
$n_d(t)$	时刻 t 设备 d 正在运行的 batch 数量
$\mathcal{P}_{m,d,b}$	DNN-设备-batch 组合的基准服务特性
$\bar{T}_{m,d,b}$	组合 (m,d,b) 的基准执行时延
$\bar{e}_{m,d,b}$	组合 (m,d,b) 的单位请求基准执行能耗
$\bar{\mu}_{m,d,b}$	组合 (m,d,b) 的基准服务率
$\Gamma_j(t)$	batch j 在运行时受到的不可直接观测减速因子
σ_j	batch j 的派发与开始执行时刻
c_j	batch j 的完成时刻
$\hat{E}_j$	batch j 的 profile-estimated 执行能耗
U_i	deployment-aware 评估中请求 i 的动作无关上行时延
L_i^{edge}	请求 i 从边缘入口起算的完成时延
L_i^{dep}	请求 i 加入动作无关上行后的部署感知时延
ε_m	DNN m 允许的长期 SLA 违约比例
$E_{\max}$	允许的 profile-estimated 单位请求能耗预算

表 3.1 汇总了后续建模使用的集合、状态和性能参数。核心系统从请求到达 edge ingress 开始；与客户端网络有关的上行只在 deployment-aware 评价中以动作无关附加时延表示，不作为调度器的控制变量。基准服务特性用于区分 DNN、设备与 batch size 的固有执行差异，而运行时减速与能耗修正表示仿真环境中的隐藏变化。

3.2 已揭示到达、FIFO 队列与事件驱动动作

为统一描述平稳到达、负载切换和模型组成漂移，本文采用分段时变泊松过程生成不同 DNN 的请求。模型 m 在区间 $[t_1, t_2)$ 内的到达数满足

$$\begin{aligned} \Lambda_m(t_1, t_2) &= \int_{t_1}^{t_2} \lambda_m(u) du, \\ A_m(t_1, t_2) &\sim \text{Poisson}(\Lambda_m(t_1, t_2)). \end{aligned} \quad (3)$$

式 (3) 中， $\Lambda_m(t_1, t_2)$ 为区间 $[t_1, t_2)$ 内模型 m 的累计到达强度， $A_m(t_1, t_2)$ 是该区间内实际到达的请求数， $\lambda_m(t)$ 是环境的瞬时到达强度。常数到达强度对应平稳泊松负载，分段变化可形成负载切换或模型 mix 漂移。调度器只能看到已经发生的到达事件，不读取瞬时到达强度的真实值或未来请求。

到达请求按 DNN 类型进入 FIFO 队列，模型 m 在时刻 t 的队列写为

$$Q_m(t) = (i_{m,1}(t), \dots, i_{m,q_m(t)}(t)). \quad (4)$$

式 (4) 中， $q_m(t)$ 为队列长度， $i_{m,\ell}(t)$ 为第 ℓ 个等待请求， $i_{m,1}(t)$ 为队首。调度动作严格按 FIFO 从队首提取请求，因而不会越过更早到达的同类请求。

系统在事件时刻 t_k 作出第 k 次决策。事件由请求到达、batch 完成或等待边界触发。联合动作 a_k 要么从 DNN m 的队首提取 b 个请求形成 batch 并派发到设备 d ，要么在满足事件推进和紧迫性条件时执行 WAIT。物理可行动作集合定义为

$$\begin{aligned} \mathcal{A}_k^{\text{phy}} &= \mathcal{A}_k^{\text{disp}} \cup \mathcal{W}_k, \\ (m, d, b) \in \mathcal{A}_k^{\text{disp}} &\iff b \in \mathcal{B}_{m,d}, \\ q_m(t_k) &\geq b, n_d(t_k) < C_d, \\ \mathcal{W}_k &\subseteq \{\text{WAIT}\}. \end{aligned} \quad (5)$$

式 (5) 中， $\mathcal{A}_k^{\text{disp}}$ 为当前可行的派发动作集合， $n_d(t_k)$ 为设备 d 当前运行的 batch 数量。队列数量、允许 batch size 和设备并发槽位共同决定派发动作是否可行。 $\mathcal{W}_k$ 是否包含 WAIT 由系统能否推进到下一个到达或完成事件以及队首请求的最晚安全等待边界共同决定，因此 WAIT 并非始终可选。风险筛选不改变该物理可行性定义。

相邻事件之间，模型 m 的队列长度按照下式演化：

$$\begin{aligned} D_{m,k} &= \sum_{d \in \mathcal{D}} \sum_{b \in \mathcal{B}_{m,d}} b \mathbb{I}[a_k \\ &\quad = (m, d, b)], \\ q_m(t_{k+1}) &= q_m(t_k) \\ &\quad + A_m(t_k, t_{k+1}) \\ &\quad - D_{m,k}. \end{aligned} \quad (6)$$

式 (6) 中， $D_{m,k}$ 表示事件 k 从模型 m 队列派发的请求数；队列更新式的第二项表示新到达请求，最后一项表示被组成 batch 并移出等待队列的请求数。若 $a_k = \text{WAIT}$ ，则 $D_{m,k} = 0$ ，请求继续留在队列并消耗 deadline 裕量。

3.3 基于 Profile 的执行过程与隐藏运行变化

为刻画不同 DNN、执行设备和 batch size 组合的固有服务差异，定义组合 (m,d,b) 的基准服务特性为

$$\mathcal{P}_{m,d,b} = (\bar{T}_{m,d,b}, \bar{e}_{m,d,b}, \bar{\mu}_{m,d,b}). \quad (7)$$

式 (7) 中， $\bar{T}_{m,d,b}$ 、 $\bar{e}_{m,d,b}$ 和 $\bar{\mu}_{m,d,b}$ 分别表示该组合的基准执行时延、单位请求基准执行能耗和基准服务率。它们是系统已知的基础参数，用于描述候选派发动作的固有执行属性；具体标定方法留在实验部分说明。

运行阶段，共置 batch 和后台资源竞争可能改变设备提供给 batch 的瞬时服务速度。对已派发 batch j，记其模型、设备、batch size 和开始时刻为 m_j 、 d_j 、 b_j 和 σ_j ，并以 $\Gamma_j(t) \geq 1$ 表示不可被调度器直接读取的有界减速因子。其完成时刻和实际计算时延由累计服务进度确定：

$$\int_{\sigma_j}^{c_j} \frac{1}{\Gamma_j(t)} dt = \bar{T}_{m_j, d_j, b_j}, \quad (8)$$

$$T_j^{\text{cmp}} = c_j - \sigma_j.$$

式 (8) 表示 batch j 需要累计获得等于基准执行时延的有效服务量。 $\Gamma_j(t)=1$ 时，实际计算时延退化为基准值；共置组成或后台竞争变化时， $\Gamma_j(t)$ 可随执行过程改变。该隐藏变量用于环境演化，但不进入策略状态，调度器只能从当前设备占用和已完成 batch 的反馈中间接适应其影响。

batch j 的执行能耗采用 profile-estimated 口径建模为

$$\hat{E}_j = b_j \bar{e}_{m_j, d_j, b_j} \phi_E(\Gamma_j, \zeta_j). \quad (9)$$

式 (9) 中， $\phi_E(\cdot)$ 是对运行时减速与隐藏执行状态 ζ_j 所引起能耗变化的有界修正。 $\hat{E}_j$ 只表示依据执行 profile 估计的 batch 能耗，不等同于整机实测总能耗，也不包括客户端通信、设备空闲和基础设施能耗。

3.4 Edge-Side 与 Deployment-Aware 指标及软约束目标

令 $j(i)$ 表示包含请求 i 的 batch。请求从到达边缘入口到所属 batch 被派发之间的排队和组批等待时延为

$$T_i^{\text{wait}} = \sigma_{j(i)} - t_i^{\text{arr}}. \quad (10)$$

式 (10) 中， $\sigma_{j(i)}$ 为请求 i 所属 batch 的派发时刻。以 edge ingress 为计时起点，请求的 edge-side 完成时延为

$$L_i^{\text{edge}} = T_i^{\text{wait}} + T_{j(i)}^{\text{cmp}}. \quad (11)$$

式 (11) 同时包含排队与组批等待以及 batch 执行时延。为评估客户端上行对 SLA 裕量的额外消耗, 进一步定义 deployment-aware 时延为

$$L_i^{\text{dep}} = U_i + L_i^{\text{edge}}. \quad (12)$$

式 (12) 中, U_i 是所有方法共享同分布样本的动作无关上行时延, 仅用于 deployment-aware evaluation。它不进入队列演化、策略状态、动作集合或训练奖励, 也不表示本文优化无线资源。edge-side 与 deployment-aware 结果在实验中分别报告。

在评价口径 $x \in \{\text{edge}, \text{dep}\}$ 下, 请求级 SLA 违约指示量定义为

$$\begin{aligned} v_i^x &= \mathbb{I}[L_i^x > \delta_{m_i}], \\ x &\in \{\text{edge}, \text{dep}\}. \end{aligned} \quad (13)$$

式 (13) 中, $v_i^x = 1$ 表示请求 i 在口径 x 下超过其模型级 deadline。令 $\mathcal{R}$ 为某一评估条件中的到达请求 cohort, 并令 $\mathcal{R}_m = \{i \in \mathcal{R}: m_i = m\}$ 。episode 结束后继续排空系统, 使该 cohort 的完成结果均被纳入统计。模型级违约率为

$$v_m^x(\mathcal{R}) = \frac{\sum_{i \in \mathcal{R}_m} v_i^x}{|\mathcal{R}_m|}. \quad (14)$$

式 (14) 使用固定到达 cohort 作为分母, 避免只统计提前完成请求造成选择偏差。系统尾部完成时延采用同一 cohort 的经验 0.99 分位数:

$$\begin{aligned} P_{99}^x(\mathcal{R}) \\ = \text{Quantile}_{0.99}(\{L_i^x: i \in \mathcal{R}\}). \end{aligned} \quad (15)$$

式 (15) 的 P_{99}^x 是实验评价指标, 不被直接写入强化学习的即时奖励。第四章采用由当前队列和 deadline 裕量构造的连续尾部风险代理, 以提供更及时的训练信号。

令 $J(\mathcal{R})$ 为完成 cohort $\mathcal{R}$ 所对应的 batch 集合, 则 profile-estimated 单位请求执行能耗为

$$\hat{E}^{\text{req}}(\mathcal{R}) = \frac{\sum_{j \in J(\mathcal{R})} \hat{E}_j}{|J(\mathcal{R})|}. \quad (16)$$

式 (16) 对 batch 执行能耗按完成请求数归一化, 单位为 J/request; 该口径不包含客户端通信、设备空闲和基础设施能耗。

设 Π 为满足信息边界的在线策略集合。以 $\bar{C}_{\text{tail}}^\pi$ 表示策略 π 下的长期平均尾部风险代理, 以 $\bar{v}_m^\pi$ 和 $\bar{E}^\pi$ 分别表示长期模型级违约率与 profile-estimated 单位请求能耗。本文采用如下软约束控制目标:

$$\begin{aligned}
& \min_{\pi \in \Pi} \overline{C}_{\text{tail}}^\pi \\
& \text{s. t. } \overline{v}_m^\pi \leq \varepsilon_m, \forall m \in \mathcal{M}, \\
& \quad \overline{E}^\pi \leq E_{\max}, \\
& \quad a_k \in \mathcal{A}_k^{\text{phy}}, \forall k.
\end{aligned} \tag{17}$$

式 (17) 在物理可行动作范围内，以模型级 SLA 上限和 `profile-estimated` 能耗预算作为软约束，并尽量降低连续尾部风险代理。该问题不声称对随机到达和隐藏减速给出确定性 SLA 保证。第四章通过模型级对偶变量、风险预算奖励和离散 SAC 近似求解；经验 p99 仍按式 (15) 独立评价。