

1 引言

面向智能交通、移动机器人和现场视觉分析等应用，DNN 推理结果只有在规定时间内返回才具有服务价值。将推理服务部署在靠近数据源的网络边缘，能够减少对远程云中心的依赖，并为实时感知与决策提供邻近算力。然而，边缘设备的资源规模有限，请求又会持续到达，因此系统不仅要完成推理，还需要在长期运行中控制请求级时效风险 [1]–[4]。

实际边缘推理平台通常同时承载多种 DNN 服务。不同模型具有不同的计算开销、到达过程和服务级目标（Service-Level Objective, SLO）；本文用模型级请求 **deadline** 表示该目标，并将超时完成记为一次服务级协议（Service-Level Agreement, SLA）违约。与此同时，高吞吐 GPU 与低功耗片上系统等执行设备在服务能力、能耗和 **batch** 扩展效率上存在差异，单一设备难以在所有模型和 **batch size** 下始终占优。因此，多 DNN 队列、异构执行设备与模型级 **deadline** 需要被统一考虑 [4]–[7]。

动态组批使上述问题进一步转化为紧密耦合的在线联合决策。等待更多同类请求可以形成较大 **batch**，提升硬件并行度并分摊执行开销，但等待本身会消耗 **deadline** 裕量；立即派发小 **batch** 可缩短排队时间，却可能降低吞吐并增加并发竞争。调度器还需决定服务哪个 DNN 队列、将 **batch** 派发到哪台设备，以及当前是否执行 **WAIT**。一次动作不仅影响当前请求，还会改变后续队列积压、设备槽位和其他模型的可服务机会 [5], [8], [9]。

这一联合决策必须在持续变化的运行条件下在线完成。短时间内的请求到达强度和模型组成可能发生波动，共置 **batch** 之间的资源竞争也会使实际执行时间偏离孤立运行时的基准水平 [2], [3], [10], [11]。调度器无法预先获知未来请求，只能依据当前队列与设备状态、已经揭示的到达事件以及已完成 **batch** 的执行反馈不断更新决策。

在此类服务中，仅优化平均时延或总体吞吐并不足以完整反映请求级服务质量。不同 DNN 的 **deadline**、执行开销和到达压力存在差异，少量长期排队或受到并发阻塞的请求可能不会显著改变系统均值，却会抬高尾部时延并增加模型级 SLA 违约。特别是在模型比例变化和突发到达条件下，系统级平均指标还可能掩盖紧 **deadline** 模型的服务退化。另一方面，若为降低时延而持续选择高性能设备或激进派发小 **batch**，也可能带来额外执行能耗。因此，在线调度需要同时关注模型级 SLA 违约风险和 **p99** 时延，并在给定能耗预算内协调及时服务与资源开销 [5], [8], [9]。

本文聚焦请求到达边缘入口后的在线服务调度。每个请求的 DNN 类型和模型级 **deadline** 由应用预先给定，调度器不改变模型、不执行网络切分、输入压缩或精度调整，也不分配无线资源。系统按照 DNN 类型维护 FIFO 队列，并由一个集中式调度器管理多个异构执行设备。**deployment-aware** 评价为所有方法叠加同分布、动作无关的客户端上行时延，以衡量网络传输对 SLA 裕量的消耗；该上行不进入策略状态、动作或训练目标。

现有研究已经分别探索动态 **batching**、并发控制、异构执行、**deadline-aware** 排序和学习式调度，但在本文场景中仍存在三个相互关联的困难。首先，当前队列和设备快照不能完整揭示短时

到达变化与运行性能偏移，策略需要从近期已完成 batch 的反馈中恢复有用的时序上下文。其次，联合动作同时包含 DNN 队列、执行设备、batch size 与 WAIT；当队列压力升高或队首请求接近 deadline 时，在全部动作上无差别探索容易放大尾部风险。最后，请求级 SLA 违约是稀疏结果，经验 p99 又只能在完整请求集合上统计，二者难以直接为每次事件提供充分训练信号；能耗还需以预算而非绝对最小值进行约束。由此，核心问题并非简单扩大策略网络，而是如何在部分可观测条件下组织历史反馈、动作风险边界和模型级约束。

为此，本文提出 **RiskBudget-SAC**。该方法首先利用 GRU 编码最近已完成 batch 的 DNN、设备、batch size、实际时延与能耗反馈，以补充当前状态对运行变化描述不足的问题；随后，反馈校准的选择性 Risk Gate 根据已经揭示的到达、当前队列压力、deadline 裕量和完成时间估计构造非空动作子集，在紧迫或高压状态优先聚焦风险较高的 DNN 队列。Actor 在 Gate 保留的动作中完成设备与 batch 决策，低风险状态下则保留完整联合选择空间。训练阶段，离散 SAC 通过模型级 SLA 对偶变量、物理时间尾部风险代理和固定能耗预算学习长期策略。动作语义编码与动作对齐 Twin Critics 作为策略骨干，用于稳定评价有限联合动作，而不被单独包装为首要创新。

总体而言，本文研究 edge-ingress 多 DNN 服务中的队列选择、设备路由、动态组批与等待控制，目标是在预设的 profile-estimated 单位请求能耗预算内降低请求级 SLA 违约率和 p99 时延。经验 p99 仅用于最终评价，训练使用与队列积压、deadline 裕量和动作持续时间相关的连续风险代理。本文的主要贡献如下：

- **部分可观测的事件驱动系统建模。** 本文将异构多 DNN 在线服务表述为具有可变动作持续时间的部分可观测事件驱动决策问题，统一描述模型级 FIFO 队列、设备并发、动态到达、运行时减速、请求级 SLA、尾部时延和 profile-estimated 能耗预算，并明确区分隐藏环境状态、当前可观测信息与部署感知评价。
- **历史反馈表示与选择性风险门控。** 本文使用 GRU 从最近已完成 batch 的执行反馈中提取时序表示，并设计反馈校准的 Risk Gate。Gate 仅利用已经揭示的到达、当前队列与 deadline 状态以及完成反馈校正的时延估计，在低风险状态保留全部物理动作，在紧迫或高压状态选择性聚焦风险主导的 DNN 及其可行动作；最终动作仍由学习策略选择。
- **模型级 SLA 约束与 p99 导向的 SAC。** 本文为不同 DNN 分别维护 SLA 对偶权重，并以队列积压、deadline 裕量和物理时间构造连续尾部风险代理；回放缓冲区保存原始风险分量，训练时先按物理时间聚合，再使用当前对偶权重重构奖励。该机制使离散 SAC 能够学习 queue-device-batch-WAIT 联合调度，同时将 profile-estimated 单位请求能耗限制在给定预算附近。
- **多层次且边界明确的实验验证。** 本文在一个冻结的 400-episode 训练检查点上，使用每条件 5 个配对环境评估种子进行 60 s 测试。相对各指标对应的最强基线，RiskBudget-SAC 在八档静态负载上将宏平均 SLA 违约率和 deployment-aware p99 分别降低约 18.8% 和 33.4%，在 random-switch 场景中分别降低约 10.0% 和 8.7%，且两类场景的 profile-estimated 单位请求能耗

均低于预设预算。上述统计不等价于多训练种子稳定性，也不表示每个负载点、每个 DNN 和每项指标均最优。

参考文献

- [1] D. Spatharakis, C. Pelekis, D. Dechouniotis, and S. Papavasileiou, “A task offloading and batch scheduling framework for edge-assisted inference,” *Future Gener. Comput. Syst.*, vol. 175, Art. no. 108030, 2026, doi: 10.1016/j.future.2025.108030.
- [2] Z. Zhao, N. Ling, N. Guan, and G. Xing, “Miriam: Exploiting elastic kernels for real-time multi-DNN inference on edge GPU,” in *Proc. 21st ACM Conf. Embedded Networked Sensor Syst. (SenSys)*, 2023, pp. 97–110, doi: 10.1145/3625687.3625789.
- [3] T.-T. Nguyen, L. Liebe, N.-Q. Tau, Y. Wu, J. Cheng, and D. Lee, “OctopInf: Workload-aware inference serving for edge video analytics,” in *Proc. IEEE Int. Conf. Pervasive Comput. Commun. (PerCom)*, 2025, pp. 128–137, doi: 10.1109/PerCom64205.2025.00032.
- [4] N. Ling, W. Lu, X. Huang, Z. Zhao, N. Guan, Z. Yan, and G. Xing, “Time-sensitive multi-DNN inference on CPU-GPU edge platforms,” *IEEE Trans. Mobile Comput.*, vol. 25, no. 5, pp. 6168–6184, May 2026, doi: 10.1109/TMC.2025.3636950.
- [5] Z. Zhang, Y. Zhao, H. Li, and J. Liu, “BCEdge: SLO-aware DNN inference services with adaptive batch-concurrent scheduling on edge devices,” *IEEE Trans. Netw. Service Manag.*, vol. 21, no. 4, pp. 4131–4145, 2024, doi: 10.1109/TNSM.2024.3409701.
- [6] S. Heidari, M. Ghasemi, Y. G. Kim, C.-J. Wu, and S. B. K. Vrudhula, “Elastic execution of multi-tenant DNNs on heterogeneous edge MPSoCs,” in *Proc. IEEE/ACM Symp. Edge Comput. (SEC)*, 2024, pp. 279–291, doi: 10.1109/SEC62691.2024.00029.
- [7] Q. Liang, W. A. Hanafy, N. Bashir, A. Ali-Eldin, D. Irwin, and P. Shenoy, “Dēlen: Enabling flexible and adaptive model-serving for multi-tenant edge AI,” in *Proc. ACM/IEEE Conf. Internet Things Design Implementation (IoTDI)*, 2023, pp. 209–221, doi: 10.1145/3576842.3582375.
- [8] G. Zhang, Y. Zhang, X. Huang, and W. Zhang, “Coinf: QoS-aware DRL-based inference task scheduling framework with batching processing,” *ACM Trans. Embedded Comput. Syst.*, vol. 25, no. 1, Art. no. 3, 20 pp., Jan. 2026, doi: 10.1145/3777373.
- [9] J. Cao, X. Li, Q. Liu, T. Han, N. Zhang, and W. Shi, “EdgeServing: Deadline-aware multi-DNN serving at the edge,” *arXiv:2605.05527*, 2026.
- [10] H. Zhang, Y. Tang, A. Khandelwal, and I. Stoica, “SHEPHERD: Serving DNNs in the wild,” in *Proc. 20th USENIX Symp. Networked Syst. Design Implementation (NSDI)*, 2023, pp. 787–808.
- [11] Y. Kim, I. Kim, K. Choi, J. Ahn, J. Park, and J. Huh, “Interference-aware DNN serving on heterogeneous processors in edge systems,” in *Proc. IEEE 42nd Int. Conf. Comput. Design (ICCD)*, 2024, pp. 199–206, doi: 10.1109/ICCD63220.2024.00038.