

4 RiskBudget-SAC 方法

RiskBudget-SAC 遵循四阶段 workflow：因果上下文构造、风险感知动作筛选、动作条件调度和尾部感知约束学习。Historical Feedback GRU 从近期完成 batch 中提取时序信息；Feedback-Calibrated Risk Gate 根据已经揭示的到达、当前压力与完成时间估计收缩高风险动作；离散 SAC 再在保留集合中完成调度，并通过模型级 SLA 对偶、物理时间尾部风险代理和固定能耗预算学习长期策略。动作语义 Actor 与动作对齐 Twin Critics 是上述方法的策略骨干，而非高于 GRU、Gate 和 SLA/p99 目标的独立主线。

4.1 方法总览与信息边界

在事件时刻 t_k ，系统能够获得各 DNN 队列、队首 deadline 裕量、设备占用与并发组成、截至当前已经发生的到达，以及最近完成 batch 的执行结果。真实到达强度、未来请求、场景标签和隐藏干扰尺度不作为 Gate 或 Actor 的显式输入。需要说明的是，环境基础 mask 中的设备忙余量等可见量可能间接携带运行变化信息，因此本文的信息边界主张限定为：Gate 的在线估计仅使用当前及历史已揭示信息，不宣称整个仿真观测严格无任何间接信息。

在低风险状态下，Gate 保留第三章式 (5) 的全部基础物理动作，Actor 统一选择 DNN、设备、batch size 或 WAIT；在紧迫或高压状态下，Gate 先聚焦风险主导的 DNN，再由 Actor 从保留的设备–batch 候选中作出最终选择。该分工避免把 Gate 误写成只删除个别动作，也避免声称 Actor 在所有分支中始终独立决定完整联合动作。

4.2 历史执行反馈表示

当前状态能够描述即时队列和设备占用，却不能完整反映短时间内的到达变化与执行性能偏移。RiskBudget-SAC 首先对已经揭示的到达进行因果在线估计。设 Δ 为统计窗口， $A_m(t_k - \Delta, t_k)$ 为窗口内已经到达的模型 m 请求数，则

$$\begin{aligned} \hat{\lambda}_{m,k} &= (1 - \alpha_\lambda) \hat{\lambda}_{m,k-1} \\ &+ \alpha_\lambda \frac{A_m(t_k - \Delta, t_k)}{\Delta}. \end{aligned} \quad (18)$$

式 (18) 中， $\hat{\lambda}_{\{m,k\}}$ 为模型 m 的在线到达率估计， α_λ 为 EWMA 平滑系数。所有 episode 采用统一冷启动，更新过程不读取环境真实 $\lambda_m(t)$ 、模型 mix 或未来请求。

执行时间估计以第三章式 (7) 的基准服务特性为起点，再由相同 DNN–设备组合的已完成 batch 反馈校正。设 $\mu^p_{\{m,d,k\}}$ 和 $\sigma^p_{\{m,d,k\}}$ 为已观测执行时延比值的 EWMA 均值与标准差，则

$$\begin{aligned} \hat{\rho}_{m,d,k} &= \text{clip}(\mu_{m,d,k}^\rho \\ &\quad + \chi \sigma_{m,d,k}^\rho, \rho_{\min}, \rho_{\max}), \end{aligned} \quad (19)$$

$$\hat{T}_k(m, d, b) = \bar{T}_{m,d,b} \hat{\rho}_{m,d,k}.$$

式 (19) 中，观测比值由已完成 batch 的实际执行时延除以基准执行时延得到， χ 控制不确定性裕量， $\text{clip}(\cdot)$ 将修正限制在有界区间。预测器不读取正在执行 batch 的真实减速因子。

令 H_k 表示 t_k 前最近 H 条已完成 batch 的反馈窗口。每条反馈保留完成新近度、batch size、实际时延与基准时延之比、实际能耗与基准能耗之比、有效标识，以及 DNN 和设备 one-hot 编码。其向量、历史编码与完整上下文分别为

$$\begin{aligned} e_j &= \left[\tilde{a}_j, \frac{\log_2 b_j}{B_{\log}} \log \frac{T_j^{\text{cmp}}}{\bar{T}_{m_j, d_j, b_j}} \log \frac{\hat{E}}{b_j \bar{e}_m} \right] \\ \mathcal{H}_k &= (e_{j-H+1}, \dots, e_j), h_k \\ &= \text{GRU}_\omega(\mathcal{H}_k), \\ c_k &= [s_k, h_k]. \end{aligned} \quad (20)$$

式 (20) 中， $\tilde{a}_j$ 为归一化反馈年龄， $B_{\log}$ 为 batch 对数尺度的归一化常数， e_m 和 e_d 分别为 DNN 与设备 one-hot 向量， h_k 为固定维度历史表示， ω 为 GRU 参数。实际实现中每条反馈为 10 维。 c_k 供 Actor 和 Critic 使用；Gate 与 GRU 并行构造，不直接读取 h_k ，而使用 s_k 、 $\hat{\lambda}_k$ 与 $\hat{T}_k$ 。

4.3 反馈校准的选择性 Risk Gate

Gate 先根据在线到达率和当前队列计算模型级压力，并以队首请求的归一化 slack 描述紧迫程度：

$$\begin{aligned} P_{m,k} &= \frac{q_m(t_k)}{\max(\lambda_{m,k} \delta_m, 1)}, \\ \tilde{s}_{m,k} &= \frac{\tau_{i_{m,l}} - t_k}{\delta_m}. \end{aligned} \quad (21a)$$

式 (21a) 中， $P_{\{m,k\}}$ 比较当前积压与一个 deadline 窗口内的估计到达量， $\tilde{s}_{\{m,k\}}$ 则把不同模型的队首裕量归一到可比较尺度。Gate 进一步计算候选派发动作的预计完成裕量：

$$\begin{aligned} M_k(m, d, b) &= \tilde{s}_{m,k} \\ &\quad - \frac{\hat{T}_k(m, d, b)}{\delta_m}. \end{aligned} \quad (21b)$$

式 (21b) 中, $M_k(m,d,b)$ 越大, 表示执行该动作后预计保留的 deadline 裕量越充足。上述量共同决定非空 Gate 动作集合:

$$\mathcal{A}_k^{\text{gate}} = G\left(s_k, \hat{\lambda}_k, \hat{T}_k, \mathcal{A}_k^{\text{phy}}\right), \quad (21c)$$

$$\emptyset \neq \mathcal{A}_k^{\text{gate}} \subseteq \mathcal{A}_k^{\text{phy}}.$$

式 (21c) 中, $G(\cdot)$ 为反馈校准的选择性门控。低压力且无紧迫请求时, Gate 保留全部物理动作; 压力升高时, Gate 先选取压力最大的 DNN, 并保留该 DNN 上预测服务率接近最佳值的设备–batch 动作; 存在紧迫请求时, Gate 先选取归一化 slack 最小的 DNN, 并优先保留预计具有完成裕量的动作。若不存在预计可及时完成的动作, 则退回到按时吞吐率或服务率较高的候选; 任何分支都必须返回非空集合。Gate 只形成允许集合, 不承诺确定性安全或 SLA 保证。

Algorithm 1: Historical-Feedback Context Construction and Selective Risk Gating

Input: 当前状态 s_k 、已揭示到达、已完成 batch 反馈、基础物理动作集合 $\mathcal{A}_k^{\text{phy}}$ 、基准服务特性

Output: 历史上下文 c_k 与非空动作集合 $\mathcal{A}_k^{\text{gate}}$

- 1 依据截至 t_k 已经发生的到达, 按式 (18) 更新各 DNN 的因果 EWMA 到达率。
- 2 同步新增完成 batch, 按式 (19) 更新相应 DNN–设备组合的执行时延修正。
- 3 构造最近 H 条完成反馈窗口 H_k , 并按式 (20) 得到 h_k 与 $c_k=[s_k, h_k]$ 。
- 4 由式 (21a) 计算各 DNN 的队列压力与归一化队首 slack。
- 5 若不存在紧迫请求且最大压力低于阈值, 则返回 $\mathcal{A}_k^{\text{gate}}=\mathcal{A}_k^{\text{phy}}$ 。
- 6 若压力较高, 则选取压力最大的 DNN, 并保留该 DNN 上预测服务率接近最佳值的物理动作。
- 7 若存在紧迫请求, 则选取归一化 slack 最小的 DNN, 并根据式 (21b) 优先保留预计可及时完成的动作。
- 8 若安全候选为空, 则依次退回到预计按时吞吐率较高和服务率较高的动作; 最后以 $\mathcal{A}_k^{\text{phy}}$ 作为非空兜底。
- 9 并行输出 c_k 与 $\mathcal{A}_k^{\text{gate}}$; Gate 不读取 GRU 隐表示, Actor 在后续步骤中使用二者。

4.4 SLA 约束与 p99 导向的 SAC

4.4.1 动作条件策略骨干

有限动作库包含 WAIT 和所有 DNN–设备–batch 组合。为使策略利用动作之间共享的模型、设备与 batch 属性, 定义动作语义向量

$$\phi(\text{WAIT}) = (\text{WAIT}),$$

$$\phi(m, d, b) = (m \cdot d \cdot b \cdot \mathcal{P}_{m,d,b}). \quad (22)$$

式 (22) 是动作属性的简写。实现时, DNN 与设备使用 one-hot 编码, batch size 同时保留对数和线性尺度, 基准执行时延、单位请求能耗与服务率在送入网络前按固定参考尺度归一化。

Actor 分别编码上下文与动作语义, 基础评分头给出有限动作库的初始分数, 动作条件残差头再细化候选动作评分:

$$\begin{aligned} z_k &= f_{\theta}^{\text{ctx}}(c_k), u_a = f_{\theta}^{\text{act}}(\phi(a)), \\ \ell_k(a) &= g_{\theta}^{\text{base}}(z_k)_a \\ &\quad + g_{\theta}^{\text{res}}(z_k, u_a). \end{aligned} \quad (23)$$

式 (23) 中, f_{ctx} 和 f_{act} 为 MLP 编码器, z_k 与 u_a 为隐空间表示。基础头保留直接评分能力, 残差头利用状态-动作交互校正该分数。该结构是 SAC 的策略实现骨干, 不改变本文以 GRU、Gate 和 SLA/p99 训练为核心的贡献层级。

策略仅在 Gate 保留的动作集合中归一化:

$$\begin{aligned} \pi_{\theta}(a|c_k) &= \frac{\mathbb{I}[a \in \mathcal{A}_k^{\text{gate}}] \exp(\ell_k(a))}{\sum_{\tilde{a} \in \mathcal{A}_k^{\text{gate}}} \exp(\ell_k(\tilde{a}))}. \end{aligned} \quad (24)$$

式 (24) 保证被基础约束或 Gate 排除的动作概率为零。训练时从该分布随机采样, 评估和部署时选择概率最大的单个动作, 不执行在线候选搜索。

两个独立 Critic 除全局上下文与动作语义外, 还读取与候选动作对应的局部队列、队首 slack、目标设备占用和并发状态:

$$\begin{aligned} Q_{\psi_j}(c_k, a) &= F_{\psi_j}(c_k, \phi(a), s_{k,a}^{\text{loc}}, j \in \{1, 2\}). \end{aligned} \quad (25)$$

式 (25) 中, $F_{\{\psi_j\}}$ 为第 j 个动作对齐 Critic, $s_{\{k,a\}}^{\text{loc}}$ 为动作相关局部状态。两个 Critic 结构相同但参数独立, Bellman target 与 Actor 更新均采用二者的较小预测值, 以抑制价值高估。

4.4.2 SLA 残差、尾部风险与能耗预算

经验 p99 需要收集完整请求 cohort 后才能计算, 难以为每个事件提供及时信号。本文对 slack 低于阈值的队列积压构造风险水平, 并按动作实际持续时间积分:

$$\begin{aligned} \xi_{m,k} &= \frac{q_m(t_k)}{\max(\lambda_{m,k} \delta_{\text{ref}}, l)} [\eta_s - \tilde{s}_{m,k}]_+^p, \\ R_k &= \text{clip}\left(\sum_{m \in \mathcal{M}} \xi_{m,k}, \theta, C_{\text{max}}\right), \\ c_k^{\text{tail}} &= \frac{R_k + R_{k+l}}{2} \frac{\Delta t_k}{\delta_{\text{ref}}}. \end{aligned} \quad (26)$$

式 (26) 中, η_s 为风险触发阈值, p 控制紧迫程度的非线性放大, δ_{ref} 为时间归一化常数, C_{max} 为数值截断上限。仅当队首 slack 进入风险区间时, 该队列才产生尾部风险; 持续时间更长的动作承担更大代价。该量是 p99 导向的训练代理, 不等同于经验 p99。

回放缓冲区保存每个聚合转移的尾部风险、模型级违约计数、请求计数和 profile-estimated 能耗。先定义模型级 SLA 残差和能耗预算超额度:

$$\begin{aligned}
g_{m,k}^{\text{SLA}} &= v_{m,k} - \varepsilon_m n_{m,k}, \forall m \in \mathcal{M}, \\
g_k^E &= \left[\hat{e}_k - E_{\max} n_k \right]_+, n_k \\
&= \sum_{m \in \mathcal{M}} n_{m,k}.
\end{aligned} \tag{27a}$$

式 (27a) 中, $v_{\{m,k\}}$ 与 $n_{\{m,k\}}$ 分别为聚合转移内模型 m 的违约请求数与 SLA 统计请求数; $g_{\{m,k\}}^{\text{SLA}}$ 为相对允许违约比例的偏差。 $\hat{e}_k$ 为累计 profile-estimated 能耗, g_k^E 仅在总能耗超过按请求数折算的预算时为正。训练奖励定义为

$$\begin{aligned}
r_k &= \\
&- \kappa [c_k^{\text{tail}} + \sum_{m \in \mathcal{M}} \lambda_{m,k}^{\text{SLA}} g_{m,k}^{\text{SLA}} + \omega_E]
\end{aligned} \tag{27b}$$

式 (27b) 中, $\lambda_{\{m,k\}}^{\text{SLA}}$ 为模型级在线对偶权重, ω_E 为固定能耗预算权重, κ 为奖励尺度。当 SLA 残差为正时惩罚增大; 残差为负时表示该模型具有 SLA 裕量。回放保存的是原始组成分量, 而非冻结后的标量奖励, 从而可在 Critic 更新时使用当前对偶权重重构 r_k 。

每个 episode 排空其到达 cohort 后, 模型级 SLA 对偶变量按观测违约率更新:

$$\begin{aligned}
\lambda_{m,k+l}^{\text{SLA}} &= \Pi[\lambda_{\min}, \lambda_{\max}] \left[\lambda_{m,k}^{\text{SLA}} \right. \\
&\quad \left. + \eta_\lambda (\hat{v}_{m,k} - \varepsilon_m) \right].
\end{aligned} \tag{28}$$

式 (28) 中, $\hat{v}_{\{m,k\}}$ 为 episode 的模型级违约率, η_λ 为对偶学习率, Π 为区间投影。不同 DNN 分别更新, 避免宽松模型掩盖紧 deadline 模型的违约压力。

4.4.3 物理时间 SAC 更新

派发与 WAIT 动作持续时间不同。物理时间 n -step 累加器首先逐分量聚合风险、能耗、违约数和请求数, 再按式 (27) 使用当前对偶权重重构累计奖励。令 N_k 为最先达到预设物理时间窗、最大决策数或 episode 边界的聚合步数, $\Delta_{\{k,\ell\}}$ 为第 ℓ 个分量前已经经过的物理时间, 则

$$\begin{aligned}
\bar{c}_k^{\text{tail}} &= \sum_{\ell=0}^{N_k-1} e^{-\beta \Delta_{k,\ell}} c_{k+\ell}^{\text{tail}}, \bar{e}_k \\
&= \sum_{\ell=0}^{N_k-1} e^{-\beta \Delta_{k,\ell}} \hat{e}_{k+\ell}, \\
\bar{v}_{m,k} &= \sum_{\ell=0}^{N_k-1} e^{-\beta \Delta_{k,\ell}} v_{m,k+\ell}, \bar{n}_{m,k} \\
&= \sum_{\ell=0}^{N_k-1} e^{-\beta \Delta_{k,\ell}} n_{m,k+\ell}.
\end{aligned} \tag{29a}$$

式 (29a) 中, β 为物理时间折扣率。用带横线的聚合分量替换式 (27a)–(27b) 中相应单步分量, 即可得到当前对偶权重下的 N -step 累计奖励 $R_k^{\text{(N)}}$ 。随后构造 soft Bellman target:

$$\begin{aligned}
\bar{V}_{k+N_k} &= \sum_{a' \in \mathcal{A}_{k+N_k}^{\text{gate}}} \pi_{\theta}(a'|c_{k+N_k}) \left[\min_j \right. \\
&\quad \left. - \alpha \log \pi_{\theta}(a'|c_{k+N_k}) \right], \\
y_k^{(N)} &= R_k^{(N)} + e^{-\beta \Delta_{k,N_k}} (I \\
&\quad - d_{k+N_k-1}) \bar{V}_{k+N_k}.
\end{aligned} \tag{29b}$$

式 (29b) 中, $Q_{\{\bar{\psi}_j\}}$ 为目标 Critic, α 为熵温度, d 为 episode 终止标记。求和仅在下一事件的 Gate 动作集合上进行; 到达 episode 边界时不引入后续价值。

两个在线 Critic 分别拟合同一 Bellman target, 其联合损失为

$$\begin{aligned}
\mathcal{L}_{Q,j} &= \mathbb{E}_{\mathcal{D}} \left[\left(Q_{\psi_j}(c_k, a_k) \right. \right. \\
&\quad \left. \left. - y_k^{(N)} \right)^2 \right], j \\
&\in \{1, 2\}, \\
\min_{\psi_1, \psi_2} \mathcal{L}_Q &= \frac{1}{2} (\mathcal{L}_{Q,1} + \mathcal{L}_{Q,2}).
\end{aligned} \tag{30}$$

式 (30) 中, $\mathcal{D}$ 为经验回放分布。两个平方误差相加而非相减; 目标 Critic 不参与反向传播, 并通过 Polyak 软更新跟随在线 Critic。回放按训练场景、压力区间与 tail risk 平衡采样, 同时保留均匀样本。

Actor 在 Gate 动作集合上采用离散 SAC 的最大熵目标:

$$\begin{aligned}
\min_{\theta} \mathcal{L}_{\pi} &= \mathbb{E}_{c_k \sim \mathcal{D}} \left[\sum_{a \in \mathcal{A}_k^{\text{gate}}} \pi_{\theta}(a|c_k) (\alpha \log \right. \\
&\quad \left. - \min_j Q_{\psi_j}(c_k, a)) \right].
\end{aligned} \tag{31}$$

式 (31) 在训练期兼顾保守价值改进与策略熵。熵温度依据 Gate 后有效动作数进行调节, 使不同状态下的探索压力具有可比性。

4.5 在线决策与训练流程

Algorithm 2: SLA-Constrained Tail-Risk-Aware SAC Training

Input: 训练场景分布、基准服务特性、物理动作库、模型级 SLA 目标 ϵ_m 与能耗预算 $E_{\max}$

Output: 训练后的 GRU、反馈估计器、Risk Gate 和确定性 Actor

- 1 初始化 Actor、在线及目标 Twin Critics、GRU、经验回放、反馈估计器和模型级 SLA 对偶变量。
- 2 在每个 episode 重置环境与因果到达率估计; 不向 Gate 或 Actor 输入真实到达率、未来请求、场景标签或隐藏干扰尺度。
- 3 在事件 t_k 调用 Algorithm 1, 得到历史上下文 c_k 与非空 Gate 动作集合 A_k^{gate} 。
- 4 训练期从式 (24) 采样动作; 执行后记录持续时间、下一状态、tail cost、模型级违约数和请求数以及 profile-estimated 能耗。
- 5 将一部分当前 tail cost 追溯到仍在阻塞相关请求的先前 batch 派发记录, 并把原始组成分量写入物理时间 n -step 累加器。

- 6 达到时间窗、最大决策数或 episode 边界时，按式 (29a) 聚合各分量并写入平衡 replay buffer。
- 7 采样 replay，使用当前 SLA 对偶权重按式 (27) 重构奖励，再按式 (29b) 计算 soft Bellman target。
- 8 按式 (30) 更新 Twin Critics，按式 (31) 更新 Actor 与熵温度，并对目标 Critic 执行 Polyak 软更新。
- 9 episode 结束并排空其到达 cohort 后，按式 (28) 更新每个 DNN 的 SLA 对偶变量。
- 10 重复上述过程直至训练结束，冻结一个检查点用于全部后续评估。

部署时移除 Twin Critics、经验回放、梯度更新和对偶更新，仅保留因果到达率估计、完成时间校正、GRU、Algorithm 1 的 Gate 以及一次确定性 Actor 前向。每个事件对有限动作库进行一次向量化评分，不执行环境内候选搜索。设历史窗口长度为 H ，物理动作数为 $|A_k^{\text{phy}}|$ ，且隐层宽度固定，则历史编码随 H 线性增长，Gate 与动作评分至多对有限动作库扫描一次，单事件复杂度关于 $|A_k^{\text{phy}}|$ 为线性量级。