

2 相关工作

本节围绕异构多 DNN 服务与动态组批、学习式在线调度与服务风险控制，以及相邻的 MEC 卸载与协同推理研究展开，并据此界定本文的研究问题。

2.1 异构多 DNN 服务与动态组批

多 DNN 在线服务需要同时处理模型间执行差异、batch 扩展特性和设备并发能力。增大 batch 通常能够提高吞吐并分摊执行开销，但也会增加组批等待；异构设备在不同模型和 batch size 下的优势并不一致，共置执行还可能引入资源竞争。因此，batch size、并发度和执行设备需要结合队列状态与 deadline 共同配置。

HarmonyBatch 面向具有不同 SLO 的 DNN 请求，在异构 CPU/GPU serverless functions 上联合完成请求分组与资源配置 [19]。ELTO 使用实测性能数据和回归预测在线调整动态组批参数，以权衡推理时延与能耗 [20]。BCEdge 则联合调节 batch size 和并发实例数，以改善边缘设备上的多 DNN 服务效率并满足 SLO [5]。这些工作说明，动态 batching 与并发控制本身已经是在线推理服务的重要基础。

在执行机制方面，Miriam 通过弹性 GPU kernel 协调实时多 DNN 推理 [2]；OctopInf 将工作负载感知的跨设备分配、动态 batching 和共置调度用于边缘视频分析 [3]。Ling 等研究 CPU-GPU 平台上的时敏多 DNN 推理 [4]，Kim 等则直接分析异构处理器上的 DNN 共置干扰，并据此改进 serving 决策 [11]。这些方法有效刻画了异构执行与批处理的系统特征，但短时到达变化和运行性能偏移仍可能使同一静态配置在不同时刻呈现不同风险，在线调度因而需要利用持续揭示的运行反馈更新判断。

2.2 学习式在线调度、SLA 与尾部风险

强化学习能够根据环境交互优化连续事件上的调度决策，并学习当前动作对后续队列、吞吐和 deadline 风险的长期影响。BCEdge 采用最大熵深度强化学习联合控制 batch size 与并发实例数 [5]。Coinf 结合性能预测识别紧急任务，并利用深度强化学习选择 QoS 感知的 batching 动作 [8]。Sun 等进一步采用离散 Soft Actor-Critic 联合学习任务卸载与 SLA 感知组批策略 [21]。因此，使用 DRL、SAC、性能预测或 urgency-aware batching 本身并不是本文的新意。

面向 deadline 与尾部性能，EdgeServing 协调多个 DNN 队列的服务顺序，以降低 deadline 违约风险 [9]；TailGuard 针对用户服务的尾部时延 SLO 设计任务级调度机制 [22]。SHEPHERD 对生产 DNN 服务负载的研究表明，在线工作负载在短时间尺度上具有明显变化，仅依赖长期均值难以完整刻画服务压力 [10]。这些研究分别证明了 deadline awareness、尾部目标与动态状态适应的必要性。

然而，在未来请求和隐藏运行扰动不可直接观测时，单个即时状态难以概括近期执行条件；若仍在全部联合动作上均匀探索，紧迫或积压状态下的试错可能进一步扩大尾部风险。现有方法也较少在同一训练过程中同时区分模型级 SLA 偏差、连续尾部风险代理和固定单位请求能耗预算。本文据此将历史反馈 GRU、选择性风险门控和 SLA/p99 导向的离散 SAC 组织为一个闭环：历史表示补充当前状态，Gate 定义状态相关的探索边界，SLA 对偶与物理时间风险代理则为 Critic 提供连续约束信号。

2.3 相邻的 MEC 卸载与协同推理

传统 MEC 研究主要决定任务在终端、边缘节点和云端之间的执行位置，并常与无线资源、计算资源或能耗控制联合优化 [12]。强化学习进一步被用于适应动态信道、任务依赖和多工作负载变化 [13]。例如，Sharma 等采用元强化学习处理具有依赖关系的边云任务卸载 [14]；Ke 等利用模块化 SAC 处理多工作负载和多 MEC 服务器的卸载决策 [15]；TF-DDRL 通过 Transformer 增强的分布式强化学习学习边云 IoT 调度 [16]。这些方法的主要动作通常是执行位置、资源份额或 DAG 调度，与持续服务队列中的 route-batch-WAIT 决策不同。

协同推理研究进一步考虑 DNN 模型结构与硬件特性。DVFO 联合选择 DNN 切分位置及 CPU、GPU 和内存的动态电压频率，以降低边云协同推理的时延与能耗 [17]。Qian 等采用循环深度强化学习联合配置无线资源、卸载比例与边缘侧多 DNN 推理 [18]。Spatharakis 等联合决定本地或远程模型、输入压缩和任务卸载，以权衡推理精度与端到端时延 [1]。这些工作同时控制通信、切分、压缩或精度变量，而本文从请求到达 edge ingress 后开始，不优化无线资源、模型切分、输入压缩或精度选择。

2.4 研究空缺总结

综上，动态 batching、异构执行、deadline-aware 排序和学习式调度均已有充分研究基础。本文关注的是三个尚未被统一处理的问题：其一，部分可观测运行条件下，当前状态需要由近期完成反馈补充，本文以 Historical Feedback GRU 对应该问题；其二，紧迫或高压状态下需要限制高风险探索，但不能用固定规则替代学习策略，本文以反馈校准的选择性 Risk Gate 构造状态相关动作边界；其三，模型级 SLA、经验 p99 与能耗预算具有不同统计语义，本文以模型级对偶约束、物理时间尾部风险代理和预算型能耗项训练离散 SAC。动作语义 Actor 与动作对齐 Twin Critics 用于实现上述策略，但不是脱离该闭环的独立研究主张。

参考文献

- [1] D. Spatharakis, C. Pelekis, D. Dechouniotis, and S. Papavasileiou, “A task offloading and batch scheduling framework for edge-assisted inference,” *Future Gener. Comput. Syst.*, vol. 175, Art. no. 108030, 2026, doi: 10.1016/j.future.2025.108030.

- [2] Z. Zhao, N. Ling, N. Guan, and G. Xing, “Miriam: Exploiting elastic kernels for real-time multi-DNN inference on edge GPU,” in Proc. 21st ACM Conf. Embedded Networked Sensor Syst. (SenSys), 2023, pp. 97–110, doi: 10.1145/3625687.3625789.
- [3] T.-T. Nguyen, L. Liebe, N.-Q. Tau, Y. Wu, J. Cheng, and D. Lee, “OctopInf: Workload-aware inference serving for edge video analytics,” in Proc. IEEE Int. Conf. Pervasive Comput. Commun. (PerCom), 2025, pp. 128–137, doi: 10.1109/PerCom64205.2025.00032.
- [4] N. Ling, W. Lu, X. Huang, Z. Zhao, N. Guan, Z. Yan, and G. Xing, “Time-sensitive multi-DNN inference on CPU-GPU edge platforms,” IEEE Trans. Mobile Comput., vol. 25, no. 5, pp. 6168–6184, May 2026, doi: 10.1109/TMC.2025.3636950.
- [5] Z. Zhang, Y. Zhao, H. Li, and J. Liu, “BCEdge: SLO-aware DNN inference services with adaptive batch-concurrent scheduling on edge devices,” IEEE Trans. Netw. Service Manag., vol. 21, no. 4, pp. 4131–4145, 2024, doi: 10.1109/TNSM.2024.3409701.
- [6] S. Heidari, M. Ghasemi, Y. G. Kim, C.-J. Wu, and S. B. K. Vrudhula, “Elastic execution of multi-tenant DNNs on heterogeneous edge MPSoCs,” in Proc. IEEE/ACM Symp. Edge Comput. (SEC), 2024, pp. 279–291, doi: 10.1109/SEC62691.2024.00029.
- [7] Q. Liang, W. A. Hanafy, N. Bashir, A. Ali-Eldin, D. Irwin, and P. Shenoy, “Dēlen: Enabling flexible and adaptive model-serving for multi-tenant edge AI,” in Proc. ACM/IEEE Conf. Internet Things Design Implementation (IoTDI), 2023, pp. 209–221, doi: 10.1145/3576842.3582375.
- [8] G. Zhang, Y. Zhang, X. Huang, and W. Zhang, “Coinf: QoS-aware DRL-based inference task scheduling framework with batching processing,” ACM Trans. Embedded Comput. Syst., vol. 25, no. 1, Art. no. 3, 20 pp., Jan. 2026, doi: 10.1145/3777373.
- [9] J. Cao, X. Li, Q. Liu, T. Han, N. Zhang, and W. Shi, “EdgeServing: Deadline-aware multi-DNN serving at the edge,” arXiv:2605.05527, 2026.
- [10] H. Zhang, Y. Tang, A. Khandelwal, and I. Stoica, “SHEPHERD: Serving DNNs in the wild,” in Proc. 20th USENIX Symp. Networked Syst. Design Implementation (NSDI), 2023, pp. 787–808.
- [11] Y. Kim, I. Kim, K. Choi, J. Ahn, J. Park, and J. Huh, “Interference-aware DNN serving on heterogeneous processors in edge systems,” in Proc. IEEE 42nd Int. Conf. Comput. Design (ICCD), 2024, pp. 199–206, doi: 10.1109/ICCD63220.2024.00038.
- [12] Y. Mao, C. You, J. Zhang, K. Huang, and K. B. Letaief, “A survey on mobile edge computing: The communication perspective,” IEEE Commun. Surveys Tuts., vol. 19, no. 4, pp. 2322–2358, 4th Quart., 2017, doi: 10.1109/COMST.2017.2745201.
- [13] N. Yang, S. Chen, H. Zhang, and R. Berry, “Beyond the edge: An advanced exploration of reinforcement learning for mobile edge computing, its applications, and future research trajectories,” IEEE Commun. Surveys Tuts., vol. 27, no. 1, pp. 546–594, Feb. 2025, doi: 10.1109/COMST.2024.3405075.
- [14] N. Sharma, A. Ghosh, R. Misra, and S. K. Das, “Deep meta Q-learning based multi-task offloading in edge-cloud systems,” IEEE Trans. Mobile Comput., vol. 23, no. 4, pp. 2583–2598, Apr. 2024, doi: 10.1109/TMC.2023.3264901.
- [15] H. Ke, Y. Ding, L. Pan, Y. Chen, and J. Zhao, “Modular deep reinforcement learning for multi-workload offloading in edge networks,” in Proc. 34th Int. Joint Conf. Artif. Intell. (IJCAI), 2025, pp. 5527–5535, doi: 10.24963/ijcai.2025/615.
- [16] Z. Wang, M. Goudarzi, and R. Buyya, “TF-DDRL: A Transformer-enhanced distributed DRL technique for scheduling IoT applications in edge and cloud computing environments,” IEEE Trans. Services Comput., vol. 18, no. 2, pp. 1039–1053, Mar./Apr. 2025, doi: 10.1109/TSC.2025.3528346.
- [17] Z. Zhang, Y. Zhao, H. Li, C. Lin, and J. Liu, “DVFO: Learning-based DVFS for energy-efficient edge-cloud collaborative inference,” IEEE Trans. Mobile Comput., vol. 23, no. 10, pp. 9042–9059, Oct. 2024, doi: 10.1109/TMC.2024.3357218.
- [18] W. Qian, R. W. L. Coutinho, and A. Boukerche, “Communication resource allocation and multi-DNN inference optimization in edge computing-aided video analytics,” Comput. Commun., vol. 257, Art. no. 108607, 2026, doi: 10.1016/j.comcom.2026.108607.
- [19] J. Chen, F. Xu, Y. Gu, L. Chen, F. Liu, and Z. Zhou, “HarmonyBatch: Batching multi-SLO DNN inference with heterogeneous serverless functions,” in Proc. IEEE/ACM 32nd Int. Symp. Quality Service (IWQoS), 2024, pp. 1–10, doi: 10.1109/IWQoS61813.2024.10682915.
- [20] I. Dokuchaev, A. K. Idrees, and R. Schuster, “ELTO: Energy-latency trade-off optimization for machine learning inference with dynamic batching,” in Proc. 23rd Int. Symp. Netw. Comput. Appl. (NCA), 2025, pp. 157–164, doi: 10.1109/NCA67271.2025.00035.
- [21] J. Sun, H. Hao, H. Shi, Z. Su, H. Li, and W. Zhang, “A dynamic co-inference framework for edge-end using discrete Soft Actor-Critic and SLA-aware task batching,” in Proc. Int. Joint Conf. Neural Netw. (IJCNN), 2025, pp. 1–9, doi: 10.1109/IJCNN64981.2025.11229166.
- [22] Z. Wang, H. Li, L. Sun, S. Rosenkrantz, H. Che, and H. Jiang, “A tail latency SLO guaranteed task scheduling scheme for user-facing services,” IEEE Trans. Parallel Distrib. Syst., vol. 36, no. 4, pp. 759–774, Apr. 2025, doi: 10.1109/TPDS.2025.3542638.