

3 系统模型与问题表述

本文研究请求到达边缘入口后的集中式在线多 DNN 推理服务。请求按 DNN 类型进入独立 FIFO 队列，调度器在请求到达、batch 完成或等待边界等事件上作出决策，并统一管理多个执行设备。本章依次定义请求与队列、事件级联合动作、基准服务特性和运行时变化，再将系统表述为具有可变动作持续时间部分可观测事件驱动决策过程，最后给出 SLA、尾部时延与能耗预算下的控制目标。

3.1 边缘入口服务架构与请求模型

设 $\mathcal{M}$ 为系统承载的 DNN 服务集合， $\mathcal{D}$ 为边缘入口统一管理的执行设备集合。系统为每个 DNN 维护一条 FIFO 队列。设备 $d \in \mathcal{D}$ 可并发运行至多 C_d 个 batch，DNN $m \in \mathcal{M}$ 在设备 d 上允许采用的 batch size 集合记为 $\mathcal{B}_{m,d}$ 。每个请求只对应一种 DNN 服务，请求不可拆分；一个 batch 仅包含同一 DNN 的请求，派发后不迁移且不抢占。

第 i 个到达边缘入口的推理请求定义为

$$r_i = (t_i^{\text{arr}}, m_i, \delta_{m_i}). \quad (1)$$

式 (1) 中， t_i^{arr} 为请求 i 到达边缘入口的时刻， m_i 为其 DNN 类型， δ_{m_i} 为该模型对应的请求级相对 deadline。请求的绝对截止时刻与时刻 t 的剩余裕量分别为

$$\tau_i = t_i^{\text{arr}} + \delta_{m_i}, s_i(t) = \tau_i - t. \quad (2)$$

式 (2) 中， τ_i 表示请求 i 的绝对截止时刻， $s_i(t)$ 表示其当前 deadline 裕量；该值越小，请求越紧迫，取负值表示请求已经超过 deadline。

表 3.1 系统对象、状态变量与性能参数

符号	定义
$\mathcal{M}$	系统提供的 DNN 服务类型集合
$\mathcal{D}$	边缘入口统一管理的执行设备集合
m	DNN 服务类型索引
d	执行设备索引
C_d	设备 d 可同时运行的 batch 数量上限
$\mathcal{B}_{m,d}$	DNN m 在设备 d 上允许采用的 batch size 集合
r_i	第 i 个到达边缘入口的推理请求
t_i^{arr}	请求 i 到达边缘入口的时刻
m_i	请求 i 对应的 DNN 类型

符号	定义
δ_m	DNN m 的请求级相对 deadline
τ_i	请求 i 的绝对截止时刻
$s_i(t)$	时刻 t 请求 i 的剩余 deadline 裕量
$\lambda_m(t)$	时刻 t DNN m 的环境到达强度；不作为策略直接输入
$\mathcal{Q}_m(t)$	时刻 t DNN m 的 FIFO 等待队列
$q_m(t)$	时刻 t DNN m 的队列请求数量
t_k	第 k 个事件驱动调度时刻
a_k	调度器在 t_k 执行的联合动作
$n_d(t)$	时刻 t 设备 d 正在运行的 batch 数量
$\mathcal{P}_{m,d,b}$	DNN-设备-batch 组合的基准服务特性
$\bar{T}_{m,d,b}$	组合 (m,d,b) 的基准执行时延
$\bar{e}_{m,d,b}$	组合 (m,d,b) 的单位请求基准执行能耗
$\bar{\mu}_{m,d,b}$	组合 (m,d,b) 的基准服务率
$\Gamma_j(t)$	batch j 在运行时受到的不可直接观测减速因子
σ_j	batch j 的派发与开始执行时刻
c_j	batch j 的完成时刻
$\hat{E}_j$	batch j 的 profile-estimated 执行能耗
U_i	deployment-aware 评估中请求 i 的动作无关上行时延
L_i^{edge}	请求 i 从边缘入口起算的完成时延
L_i^{dep}	请求 i 加入动作无关上行后的部署感知时延
ε_m	DNN m 允许的长期 SLA 违约比例
$E_{\max}$	允许的 profile-estimated 单位请求能耗预算

表 3.1 汇总了后续建模使用的对象、状态变量和性能参数。核心系统从请求到达 edge ingress 开始；与客户端网络有关的上行只在 deployment-aware 评价中以动作无关附加时延表示，不作为调度控制变量。

3.2 已揭示到达、FIFO 队列与事件驱动动作

为统一描述平稳到达、负载切换和模型组成漂移，本文采用分段时变泊松过程表示不同 DNN 的请求到达。模型 m 在区间 $[t_1, t_2)$ 内的到达数满足

$$\begin{aligned} \Lambda_m(t_1, t_2) &= \int_{t_1}^{t_2} \lambda_m(u) du, \\ A_m(t_1, t_2) &\sim \text{Poisson}(\Lambda_m(t_1, t_2)). \end{aligned} \quad (3)$$

式 (3) 中， $\Lambda_m(t_1, t_2)$ 为累计到达强度， $A_m(t_1, t_2)$ 为实际到达请求数， $\lambda_m(t)$ 为环境的瞬时到达强度。调度器只能观察已经发生的到达事件，不直接读取 $\lambda_m(t)$ 的真实值或未来请求。

到达请求按 DNN 类型进入 FIFO 队列，模型 m 在时刻 t 的队列写为

$$Q_m(t) = (i_{m,1}(t), \dots, i_{m,q_m(t)}(t)). \quad (4)$$

式 (4) 中， $q_m(t)$ 为队列长度， $i_{\{m,1\}}(t)$ 为队首请求。调度动作严格按 FIFO 从队首提取请求，因而不会越过更早到达的同类请求。

系统在事件时刻 t_k 作出第 k 次决策。联合动作 a_k 要么从 DNN m 的队首提取 b 个请求组成 batch 并派发到设备 d ，要么在系统可以推进至下一已揭示事件时执行 WAIT。实现接口首先构造基础物理动作集合：

$$\begin{aligned} \mathcal{A}_k^{\text{phy}} &= \mathcal{A}_k^{\text{disp}} \cup \mathcal{W}_k, \\ (m, d, b) \in \mathcal{A}_k^{\text{disp}} &\iff \\ &\quad \in \mathcal{B}_{m,d}, \quad q_m(t_k) \\ &\quad \geq b, \quad n_d(t_k) \\ &\quad < C_d, \\ \mathcal{W}_k &\subseteq \{\text{WAIT}\}. \end{aligned} \quad (5)$$

式 (5) 中，派发动作由队列数量、允许 batch size 和设备并发槽位共同约束。WAIT 还需满足事件可推进条件和基于当前可见状态及基准服务特性的最晚等待边界。该集合属于环境提供的基础动作 mask；第四章的 Risk Gate 在其上进一步筛选。由于设备忙余量等可见量可能间接反映正在发生的运行变化，本文仅主张 Gate 的在线估计不显式读取真实负载系数、未来请求、场景标签或隐藏干扰尺度，而不将整个仿真观测宣称为严格无信息泄漏。

相邻事件之间，模型 m 的队列长度按照下式演化：

$$\begin{aligned} D_{m,k} &= \sum_{d \in \mathcal{D}} \sum_{\substack{b \in \mathcal{B}_{m,d} \\ = (m, d, b)}} b \mathbb{I}[a_k \\ &\quad = (m, d, b)], \\ q_m(t_{k+1}) &= q_m(t_k) \\ &\quad + A_m(t_k, t_{k+1}) \\ &\quad - D_{m,k}. \end{aligned} \quad (6)$$

式 (6) 中, $D_{\{m,k\}}$ 表示事件 k 从模型 m 队列派发的请求数。若 $a_k = \text{WAIT}$, 则 $D_{\{m,k\}} = 0$, 请求继续留在队列并消耗 deadline 裕量。

系统的完整环境状态还包括瞬时到达强度、模型组成和运行时减速等隐藏变量。调度器在 t_k 只能获得当前队列、 deadline 裕量、设备状态、已经揭示的到达以及已完成 batch 反馈, 并据此形成历史依赖的决策。令 x_k 、 o_k 和 Δt_k 分别表示隐藏环境状态、当前可观测信息和动作持续时间, 则

$$\begin{aligned} x_k &= (\lambda(t_k), \chi(t_k), \Gamma(t_k), \zeta(t_k)), \\ o_k &= (s_k, A(0, t_k), \mathcal{H}_k), a_k \sim \pi(\cdot | o_{0:k}) \\ \Delta t_k &= t_{k+1} - t_k. \end{aligned} \quad (6a)$$

式 (6a) 中, $\chi(t_k)$ 表示请求模型组成, $\Gamma(t_k)$ 与 $\zeta(t_k)$ 表示运行时减速及其隐藏状态, $\mathcal{H}_k$ 为截至当前已经完成 batch 的反馈历史。不同派发动作和 WAIT 的持续时间并不相同, 因此该问题具有部分可观测、可变持续时间的 semi-Markov 特征; 第四章利用历史反馈 GRU 近似恢复与决策相关的运行上下文。

3.3 基准服务特性与运行时变化

为刻画不同 DNN、执行设备和 batch size 组合的固有差异, 定义组合 (m, d, b) 的基准服务特性为

$$\mathcal{P}_{m,d,b} = (\bar{T}_{m,d,b}, \bar{e}_{m,d,b}, \bar{\mu}_{m,d,b}). \quad (7)$$

式 (7) 中, $\bar{T}_{\{m,d,b\}}$ 、 $\bar{e}_{\{m,d,b\}}$ 和 $\bar{\mu}_{\{m,d,b\}}$ 分别表示基准执行时延、单位请求基准执行能耗和基准服务率。它们是系统已知的基础参数, 具体标定过程留在实验部分。

运行阶段, 共置 batch 和后台资源竞争可能改变设备的瞬时服务速度。对已派发 $\text{batch } j$, 记其模型、设备、 batch size 和开始时刻为 m_j 、 d_j 、 b_j 和 σ_j , 并以 $\Gamma_j(t) \geq 1$ 表示环境中的有界减速因子。其完成时刻和实际计算时延由累计服务进度确定:

$$\begin{aligned} \int_{\sigma_j}^{c_j} \frac{1}{\Gamma_j(t)} dt &= \bar{T}_{m_j, d_j, b_j}, \\ T_j^{\text{cmp}} &= c_j - \sigma_j. \end{aligned} \quad (8)$$

式 (8) 表示 $\text{batch } j$ 需要累计获得等于基准执行时延的有效服务量。隐藏减速尺度不被显式提供给 Gate 或策略; 其影响可通过设备当前占用、 busy remaining 和已完成 batch 的反馈被间接观察。因此, 本文讨论的是基于可见结果的在线适应, 而非对隐藏状态的直接访问。

$\text{batch } j$ 的执行能耗采用 profile-estimated 口径表示为

$$\hat{E}_j = b_j \bar{e}_{m_j, d_j, b_j} \phi_E(\Gamma_j, \zeta_j). \quad (9)$$

式 (9) 中, $\varphi_E(\cdot)$ 是运行时减速和隐藏执行状态引起的有界修正。 $\hat{E}_j$ 不等同于整机实测总能耗, 也不包括客户端通信、设备空闲和基础设施能耗。

3.4 时延、SLA 与能耗指标

令 $j(i)$ 表示包含请求 i 的 batch。其排队与组批等待时延为

$$T_i^{\text{wait}} = \sigma_{j(i)} - t_i^{\text{arr}}. \quad (10)$$

式 (10) 中, $\sigma_{j(i)}$ 为请求 i 所属 batch 的派发时刻。edge-side 完成时延为

$$L_i^{\text{edge}} = T_i^{\text{wait}} + T_{j(i)}^{\text{cmp}}. \quad (11)$$

式 (11) 同时包含等待与 batch 执行时延。为评估动作无关上行对 SLA 裕量的额外消耗, 定义 deployment-aware 时延为

$$L_i^{\text{dep}} = U_i + L_i^{\text{edge}}. \quad (12)$$

式 (12) 中, U_i 是所有方法共享同分布样本的动作无关上行时延, 仅用于 deployment-aware evaluation, 不进入队列演化、策略状态、动作集合或训练奖励。

在评价口径 $x \in \{\text{edge}, \text{dep}\}$ 下, 请求级 SLA 违约指示量定义为

$$v_i^x = \mathbb{I}[L_i^x > \delta_{m_i}], \quad x \in \{\text{edge}, \text{dep}\}. \quad (13)$$

式 (13) 中, $v_i^x=1$ 表示请求 i 在口径 x 下超过模型级 deadline。令 $\mathcal{R}$ 为某评估条件下的到达请求 cohort, $\mathcal{R}_m = \{i \in \mathcal{R} : m_i = m\}$, 模型级违约率为

$$v_m^x(\mathcal{R}) = \frac{\sum_{i \in \mathcal{R}_m} v_i^x}{|\mathcal{R}_m|}. \quad (14)$$

式 (14) 使用固定到达 cohort 作为分母, episode 结束后继续排空系统, 使该 cohort 的结果均进入统计。系统尾部完成时延定义为

$$P_{99}^x(\mathcal{R}) = \text{Quantile}_{0.99}(\{L_i^x : i \in \mathcal{R}\}). \quad (15)$$

式 (15) 是最终评价指标, 不直接写入即时奖励。第四章使用由当前队列、deadline 裕量和物理时间构成的连续风险代理。

profile-estimated 单位请求执行能耗为

$$\hat{E}^{\text{req}}(\mathcal{R}) = \frac{\sum_{j \in \mathcal{J}(\mathcal{R})} \hat{E}_j}{|\mathcal{R}|}. \quad (16)$$

式 (16) 中, $\mathcal{J}(\mathcal{R})$ 为完成 cohort $\mathcal{R}$ 的 batch 集合; 该口径不包含客户端通信、设备空闲和基础设施能耗。

3.5 控制目标

设 Π 为满足上述信息边界的在线策略集合， $\bar{C}_{\text{tail}}^\pi$ 、 $\bar{v}_m^\pi$ 和 $\bar{E}^\pi$ 分别表示策略 π 下的长期平均尾部风险代理、模型级违约率和 profile-estimated 单位请求能耗。本文将模型级 SLA 作为约束，将超出预算的能耗作为固定 hinge 代价，并最小化尾部风险：

$$\begin{aligned} \min_{\pi \in \Pi} & \bar{C}_{\text{tail}}^\pi + \omega_E \left[\bar{E}^\pi - E_{\max} \right]_+, \\ \text{s. t. } & \bar{v}_m^\pi \leq \varepsilon_m, \forall m \in \mathcal{M}, \\ & a_k \in \mathcal{A}_k^{\text{phy}}, \forall k. \end{aligned} \tag{17}$$

式 (17) 中， ω_E 为固定能耗预算权重， $E_{\max}$ 为 profile-estimated 单位请求能耗预算。能耗项并非独立对偶约束，而只惩罚超出预算的部分；模型级 SLA 则在第四章中由在线对偶变量近似处理。经验 p99 按式 (15) 独立评价，训练目标采用 $\bar{C}_{\text{tail}}^\pi$ 作为其稠密代理。该问题不对随机到达和隐藏运行变化给出确定性 SLA 保证。